Instituto Tecnológico y de Estudios Superiores de Monterrey

Inteligencia artificial avanzada para la ciencia de datos

Data Preparation

Facundo Bautista Barbera
A01066843

Emiliano Camacho Ponce
A01712408

Oswaldo Isaías Hernández Santes
A01199004

Iker Mejía Hernández
A01352358

Alfredo Alejandro Soto Herrera
A01711368

Jorge Manuel Oyoqui Aguilera
A01711783

2 de noviembre de 2026

Índice

Resumen **3**

Adaptaciones a CRISP-DM **3**

3.1 Seleccionar los datos **4**
3.1.1 Base lógica para la inclusión y exclusión 4

3.2 Limpiar los datos **5**
3.2.1 Reporte de limpieza de datos 5

3.3 Construir los datos **7**
3.3.1 Atributos derivados 7
3.3.2 Registros generados 10

3.4 Integrar los datos **10**
3.4.1 Datos integrados 10

3.5 Formatear los datos **10**
3.5.1 Datos reformateados 10

3.6 Entregables de la fase **11**
3.6.1 Dataset 11
3.6.2 Descripción del dataset 12
3.6.3 Pendientes por aclarar 14

Resumen

El objetivo de minería de datos del proyecto es predecir la condición corporal (BCS, por sus siglas en inglés) de las vacas del CAETEC a partir de fotografías. El desempeño del modelo se medirá con el error absoluto medio (MAE) y con la exactitud (*accuracy*). En esta fase preparamos solo los datos de BCS, que son las fotos de la visita del 14 de octubre de 2026 y la bitácora de los expertos. El resultado es un dataset listo para la fase de modelado: fotos en JPG separadas por vista, un índice con el BCS de cada foto y una separación en 5 pliegues por vaca.

Datos importantes del dataset final:

- Partimos de 477 archivos de fotos y 83 evaluaciones de la bitácora (69 vacas). El dataset final tiene 333 fotos de 67 vacas y 81 evaluaciones de BCS.
- De esas fotos, 325 de 66 vacas se usan para entrenar. Las otras 8 son fotos descartadas al marcar la vista (borrosas, cortadas, tapadas o en una vista que no sirve).
- Por vista hay 214 fotos posteriores, 58 laterales izquierdas y 53 laterales derechas.
- Las vacas se reparten en 5 pliegues separados por vaca, de 13 o 14 vacas cada uno, con un BCS medio de entre 3.00 y 3.05 en todos.
- Excluimos la vaca 2123 completa y las 4 fotos que aparecían idénticas en las vacas 1548 y 2107. La 2107 se quedó sin fotos y la 1554 se quedó sin fotos usables, así que ninguna de las dos entra al entrenamiento.
- Las fotos pasaron a JPG a resolución completa y el dataset pesa 1.61 GB.

Adaptaciones a CRISP-DM

En esta fase hicimos los siguientes ajustes a CRISP-DM:

- Mantenemos el orden de las tareas 3.1 a 3.5, pero la conversión de las fotos a JPG, que es parte de 3.5, la hacemos antes de 3.3. La vista de cada foto se marca a mano en una página que corre en el navegador, y el navegador no puede mostrar fotos HEIC.
- Preparamos solo los datos de BCS (fotos y bitácora), porque los datos de ordeño no son entrada del modelo. Por eso esta fase usa un solo notebook de Python. Se llama 01_dp_bcs_problem.ipynb y está en la carpeta src/notebooks/03-data-preparation/ del repositorio.
- Todo se escribe en la carpeta data/, que no se sube al repositorio, y los archivos originales nunca se modifican.
- La separación en 5 pliegues por vaca es la tarea 4.2 de CRISP-DM (diseño de prueba), pero la hacemos aquí para que el dataset salga listo para entrenar.
- No hay registros generados. La descripción del dataset la hacemos con las tablas de columnas de la sección 3.6.2 y con un LEEME.md que mantiene el equipo en el bucket de S3.

3.1. Seleccionar los datos

3.1.1. Base lógica para la inclusión y exclusión

Decidimos qué datos entran con los tres criterios que pide el curso: relevancia para el objetivo del proyecto (predecir el BCS), calidad de los datos y restricciones técnicas.

Cuadro 1: Fuentes que entran y que no entran a la preparación.

Fuente	¿Entra?	Razón
Fotos de la visita al CAETEC del 14/10/2026	Sí	Son la entrada del modelo de visión. Son 355 fotos de 69 vacas sin contar copias.
Bitácora: columnas ID, hora y BCS	Sí	El BCS de los expertos es la etiqueta.
Bitácora: columnas Foto y Carpeta	No	Son ligas de Drive. La relación entre foto y vaca ya viene en las carpetas.
Conjunto de datos de VMS 3 (vms-3.csv)	No	Solo 13 de las 69 vacas con BCS están en este conjunto y no es entrada del modelo de imágenes.
Columna "Evento BCS" de VMS 3	No	No coincide con el BCS de los expertos y todavía no sabemos qué mide (véase 2.4).
CSV de ordeño	No	Solo 12 vacas con BCS tienen datos de ordeño y son de marzo a julio de 2025, más de un año antes de las fotos.

Otras decisiones de esta tarea:

- No hicimos pruebas de significancia ni de correlación entre campos, porque la entrada del modelo son imágenes y no una tabla de atributos.
- No hicimos muestreo ni pesos de atributos. Tenemos pocas vacas y las fotos únicas pesan cerca de 0.79 GB, así que usamos todas las fotos disponibles.
- No recolectamos datos adicionales en esta fase.
- Si el socio formador responde qué mide "Evento BCS", volvemos a evaluar si se usa.

Cómo obtuvimos las cifras

Todas las cifras de esta fase salen de correr completo el notebook 01_dp_bcs_problem.ipynb sobre las fotos originales (477 archivos), la bitácora (etiquetas_bsc.xlsx) y el archivo vistas.csv con las vistas marcadas a mano. La corrida terminó sin errores y el índice que generó coincide con el índice de referencia que ya estaba en el bucket (333 filas, mismas columnas y ninguna diferencia). Es decir, el notebook reproduce exactamente el dataset del bucket. El notebook busca la carpeta data/ subiendo desde su ubicación, así que no depende de una ruta fija.

3.2. Limpiar los datos

3.2.1. Reporte de limpieza de datos

Hicimos la limpieza sobre los problemas que encontramos en 2.4. Para cada uno decidimos si lo corregimos, lo eliminamos o lo ignoramos, que son las tres estrategias del curso. Ningún archivo original se borra: lo que se elimina solo deja de usarse y queda registrado en fotos.csv (columnas `excluida` y `motivo`).

Cuadro 2: Problemas de calidad y cómo los tratamos.

Problema (2.4)	Estrategia	Qué hicimos	Resultado
Copias exactas dentro de una misma vaca (carpetas descargadas dos veces y nombres tipo IMG_0530(1).HEIC)	Eliminar	Dejamos una sola copia por huella digital (SHA-256) dentro de cada vaca. Cuando hay varias, nos quedamos con la que no lleva "(1)".	De 477 archivos se quitaron 122 copias y quedaron 355 fotos únicas.
Fotos idénticas en dos vacas (1548 y 2107)	Eliminar	Quitamos esas fotos de las dos vacas porque no sabemos a cuál pertenecen.	Se excluyeron 8 filas de fotos (4 fotos en 2 vacas). La 1548 conserva sus 3 fotos propias y la 2107 se queda sin fotos.
Vaca 2123 con dos carpetas de fotos distintas que se enciman	Eliminar	Excluimos la vaca completa, porque no se sabe qué fotos van con cada una de sus dos evaluaciones y adivinar podría asignar un BCS equivocado.	Se excluyeron 14 fotos y 2 evaluaciones.
Hora de la bitácora con "x" o con otro formato	Corregir e ignorar	"13 00" pasa a "13:00". Las "x" y los formatos raros quedan vacíos y el valor original se guarda en `hora_original`. La hora no se usa en el modelo.	De 83 filas, 16 quedan con la hora vacía (14 con "x" y 2 con otro formato).
BCS con coma decimal o fuera de escala	Corregir y verificar	El BCS se convierte a número y se revisa que esté entre 1 y 5 en pasos de 0.25.	Ningún BCS quedó sin convertir, fuera de rango ni fuera de los pasos de 0.25.
Fotos del Samsung S22 con orientación EXIF distinta de 1	Corregir	Los JPG con orientación distinta de 1 se enderezan. En los HEIC la librería ya aplica la rotación al abrirlos.	20 JPG se enderezaron. Los otros 4 JPG ya estaban derechos y se copiaron sin cambios.
Dos formatos (HEIC y JPG) y varias resoluciones	Corregir	Todo pasa a JPG (véase 3.5). La resolución no se cambia en esta fase.	Véase la sección 3.5.1.
14 vacas con dos evaluaciones de BCS distintas	Ignorar, documentado	No eliminamos ninguna evaluación. Guardamos las dos y entrenamos con el promedio (véase 3.3.1).	13 de esas vacas siguen en el dataset, porque la 2123 se excluyó.
Valores faltantes	Ignorar, documentado	No imputamos nada, porque no tenemos campos numéricos con faltantes que estimar.	No aplica.

Cifras de la limpieza:

- **Fotos:** se leyeron 477 archivos, se quitaron 122 copias exactas y quedaron 355 fotos únicas.

Se excluyeron 22 (14 de la vaca 2123 y 8 filas repetidas entre la 1548 y la 2107), así que siguen 333 fotos de 67 vacas.

- **Bitácora:** tiene 83 evaluaciones, se excluyeron 2 (las de la 2123) y la bitácora limpia queda con 81 evaluaciones.

Pendientes que siguen abiertos y su posible efecto

- Las 7 vacas con etiqueta "fresca" contradictoria entre los expertos y el conjunto de datos de VMS 3 siguen sin auditarse con el CAETEC. Si alguna etiqueta está mal, afecta directamente al BCS de entrenamiento y a las métricas.
- Al excluir la 2123 y la 2107 perdemos vacas y fotos en un dataset que ya es chico. **Pendiente:** confirmar en equipo la exclusión de la vaca 2123.
- Hay clases de BCS con muy pocas vacas (2.25 tiene una sola evaluación), así que las métricas pueden moverse mucho con un solo error.
- Las vistas de las 333 fotos las marcó una sola persona del equipo el 26/10/2026. **Pendiente:** definir si otra persona revisa una muestra de las marcas.

3.3. Construir los datos

3.3.1. Atributos derivados

Los atributos derivados que construimos son la vista de cada foto, si la foto es usable, el BCS de entrenamiento, el número de evaluaciones, la diferencia entre evaluadores, el pliegue y el número de fotos usables por vista de cada vaca.

Vista y foto usable

Ni los nombres ni los metadatos de las fotos dicen la vista, así que la marcamos a mano con la página marcar_vistas.html. Con una tecla se marca 1 posterior, 2 lateral izquierda, 3 lateral derecha o 0 descartar (borrosa, cortada, tapada o en una vista que no sirve). Izquierda y derecha son del lado de la vaca y no de la foto. Cada marca guarda quién la hizo y cuándo. Las fotos descartadas no se borran: quedan en una carpeta aparte. Las que no se marquen quedarían en sin_marcar y no se usarían; en nuestra corrida no quedó ninguna sin marcar. **Pendiente:** decidir si marcar_vistas.html entra al repositorio o solo se menciona.

Cuadro 3: Fotos por vista.

Vista	Fotos	Vacas con al menos una foto usable
Posterior	214	59
Lateral izquierda	58	26
Lateral derecha	53	22
Descartadas	8	No aplica
Total	**333**	**66 vacas con fotos usables**

- De las 66 vacas con fotos usables, 22 no tienen ninguna foto lateral y 7 no tienen foto posterior. Solo 4 tienen las dos laterales.
- La mediana es de 4 fotos usables por vaca, con un mínimo de 1 (6 vacas) y un máximo de 14.
- Las 8 fotos descartadas son de las vacas 1507, 1516, 1517, 1536, 1554, 1578 (2 fotos) y 2114. La 1554 tenía una sola foto y por eso no tiene fotos usables.

Etiqueta de BCS

A algunas vacas las evaluaron dos veces y decidimos no elegir una evaluación sobre la otra, como acordamos en la tabla de riesgos de 2.4:

- `bcs_1` y `bcs_2` son las dos evaluaciones en el orden de la bitácora. El orden no indica qué experto dio cada una.
- `n_eval` es el número de evaluaciones de la vaca.
- `bcs_entrenamiento` es el promedio de las evaluaciones y es la etiqueta con la que se entrena. Si solo hay una evaluación, es esa.
- `dif_evaluadores` es la diferencia entre las dos evaluaciones, cuando hay dos.

Para evaluar el modelo se compara contra cada evaluación real (evaluaciones.csv) y no contra el promedio. Las 13 vacas con dos evaluaciones que siguen en el dataset tienen una diferencia media de 0.115 y máxima de 0.25, y en 7 de ellas las dos evaluaciones son iguales.

Cuadro 4: Vacas por BCS de entrenamiento.

BCS de entrenamiento	Vacas
2.250	1
2.500	12
2.625	1
2.750	12
3.000	12
3.125	4
3.250	9
3.375	1
3.500	8
3.750	6
Total	**66**

Los valores como 2.625, 3.125 y 3.375 salen de promediar dos evaluaciones distintas.

Pliegues de validación cruzada

Repartimos las vacas en 5 pliegues ($k = 5$). En CRISP-DM esto es la tarea 4.2 (diseño de prueba), pero lo hacemos aquí para que el dataset salga listo para entrenar.

- La separación es por vaca y no por foto. Todas las fotos de una vaca quedan en el mismo pliegue. Si una vaca tuviera fotos en entrenamiento y en prueba, el modelo podría aprender a reconocerla en lugar de aprender su BCS y las métricas saldrían infladas (*data leakage*).
- Los pliegues no son aleatorios. Ordenamos las vacas por BCS de entrenamiento (y por ID cuando empatan) y las asignamos en rotación: 0, 1, 2, 3, 4, 0, 1 y así. De esta forma cada pliegue tiene BCS bajos, medios y altos, y el reparto sale igual en cada corrida.
- Una vaca recibe pliegue solo si tiene al menos una foto usable y BCS.

Cuadro 5: Vacas, fotos y BCS medio por pliegue.

Pliegue	Vacas	Fotos	Posterior	Lateral izq.	Lateral der.	BCS medio
0	14	72	56	14	2	3.01
1	13	76	48	10	18	3.00
2	13	60	38	8	14	3.02
3	13	57	34	13	10	3.04
4	13	60	38	13	9	3.05

Los pliegues quedan parejos en BCS, pero no en vistas: el pliegue 0 tiene solo 2 laterales derechas y el 1 tiene 18. Esto puede afectar a los modelos que usen una sola vista.

Otras decisiones

- **Normalización:** en esta fase no cambiamos la resolución ni los valores de los píxeles. Las fotos se quedan a resolución completa y se reducen después, al entrenar.
- **Profundidad:** las 70 fotos del dataset final cuyo HEIC traía mapa de profundidad del LiDAR solo se registran (columna `profundidad`). No se guardan los mapas.

3.3.2. Registros generados

No aplican. No inventamos fotos ni vacas nuevas.

3.4. Integrar los datos

3.4.1. Datos integrados

Juntamos las fotos, las vistas, el BCS y los pliegues en tres tablas:

- indice_imagenes.csv tiene una fila por foto (333) con su ruta, vista, BCS y pliegue. Para entrenar se usan las filas con `usar_en_entrenamiento` igual a "si", que son las fotos usables de vacas con pliegue (325 fotos de 66 vacas).
- vacas.csv tiene una fila por vaca (67) con su pliegue, su BCS y cuántas fotos usables tiene de cada vista.
- evaluaciones.csv tiene una fila por evaluación real de BCS (81). Incluye también a las vacas que no entran al entrenamiento, marcadas con `en_entrenamiento` igual a "no". De las 81 evaluaciones, 79 son de vacas que entran al entrenamiento y 2 no (la 2107 y la 1554).

No integramos el conjunto de datos de VMS 3 ni los datos de ordeño. Los cruces que vimos en 2.3 (13 vacas con VMS 3, 12 con ordeño y solo 2 en las tres fuentes) no alcanzan para usarlos como entrada.

Las tres tablas se arman con la misma lógica en dos caminos, pandas y PySpark, y comparamos que den el mismo resultado. El notebook usa pandas y PySpark queda como comparación (véase la sección 3.6.1).

3.5. Formatear los datos

3.5.1. Datos reformateados

- **Formato:** todas las fotos pasan a JPG con calidad 95 y a resolución completa. De las 333 fotos finales, 309 venían en HEIC y 24 en JPG. Se convirtieron 329 y se copiaron sin cambios 4, que son los JPG que ya venían derechos, para no perder calidad. Ninguna foto dio error.
- **Nombres:** conservamos el nombre original sin el "(1)". Si dos fotos distintas de una vaca quedan con el mismo nombre, se agregan 8 caracteres de la huella.

- **Resolución:** no la cambiamos. Quedan 270 fotos de 4284×5712, 39 de 3024×4032, 20 de 3000×4000 (las del Samsung ya enderezadas) y 4 de otros tamaños.
- **Escritura segura:** la conversión escribe primero un archivo .tmp y luego lo renombra. Si el JPG ya existe, no lo vuelve a convertir. Así se puede volver a correr el notebook sin duplicar trabajo.
- **Estructura:** las fotos se organizan como imagenes/<vista>/<id_vaca>/<foto>.jpg, y las tres tablas se ordenan por ID de vaca como número. Las columnas tienen el mismo orden y los mismos nombres en pandas y en PySpark.
- **Copias:** las fotos se copian a data/dataset_bcs/ en lugar de moverse. Así la carpeta data/intermedios/ queda completa y el proceso se puede reproducir. Al final se revisa que cada ruta del índice exista: en nuestra corrida faltaron 0 rutas y sobraron 0 archivos.

3.6. Entregables de la fase

3.6.1. Dataset

El dataset es la carpeta data/dataset_bcs/, que se sube al bucket de S3 del equipo:

```
dataset_bcs/
    imagenes/
        posterior/<id_vaca>/<foto>.jpg
        lateral_izq/<id_vaca>/<foto>.jpg
        lateral_der/<id_vaca>/<foto>.jpg
        descartadas/<id_vaca>/<foto>.jpg
    indice_imagenes.csv
    vacas.csv
    evaluaciones.csv
    tiempos.csv
    LEEME.md
```

Cuadro 6: Resumen del dataset.

Concepto	Valor
Fotos	333 de 67 vacas
Fotos para entrenar	325 de 66 vacas
Evaluaciones de BCS	81 (79 de vacas que entran al entrenamiento)
Pliegues	5, separados por vaca
Tamaño	1.61 GB

Las rutas de los CSV son relativas a dataset_bcs/, así que al descargar el dataset hay que conservar esta estructura. El nombre del bucket no se escribe en el repositorio: los notebooks lo leen de la variable de entorno `S3_BUCKET`. **Pendiente:** indicar en qué carpeta del bucket queda dataset_bcs/.

Comparación entre pandas y PySpark

El paso de integración, el diseño de prueba y la construcción de la etiqueta también los programamos con PySpark, en un contenedor Docker con Java 11 y Spark 3.5.0. Lo hicimos para practicar un enfoque que serviría si el volumen creciera. Los scripts de esa versión están en el bucket del equipo y no en el repositorio. **Pendiente:** decidir qué pasa con los scripts del bucket.

Las dos versiones generaron exactamente el mismo índice. Con este volumen, PySpark tardó unas 40 veces más en total, por el costo de arrancar Spark (mediana de 5 corridas, tiempos.csv).

Cuadro 7: Tiempos de pandas y PySpark (mediana de 5 corridas).

Versión	Total (s)	Arranque de sesión (s)	Procesamiento (s)
pandas	0.229	No aplica	0.027
PySpark (modo local)	9.237	1.798	6.492

Por eso el notebook usa pandas y PySpark queda como comparación. **Pendiente:** definir si el procesamiento se pasa a PySpark en AWS, como pide el contexto del curso.

3.6.2. Descripción del dataset

La descripción completa está en el LEEME.md del bucket. Aquí resumimos las columnas de cada tabla.

`indice_imagenes.csv` (una fila por foto)

Cuadro 8: Columnas de `indice_imagenes.csv`.

Columna	Descripción
`ruta`	Ruta de la foto dentro de dataset_bcs/.
`id_vaca`	ID de la vaca (conviene leerlo como texto).
`vista`	posterior, lateral_izq o lateral_der. Queda vacío si la foto se descartó.
`usable`	si o no. Vale no cuando la foto se descartó por estar borrosa, cortada, tapada o en una vista que no sirve.
`usar_en_entrenamiento`	si cuando la foto es usable y su vaca tiene pliegue.
`fold`	Pliegue de validación cruzada (0 a 4). Vacío si la vaca no entra.
`bcs_entrenamiento`	BCS con el que se entrena: el promedio de las evaluaciones de la vaca.
`bcs_1`, `bcs_2`	Evaluaciones originales. `bcs_2` queda vacío si solo hubo una.
`n_eval`	Número de evaluaciones de la vaca (1 o 2).
`dif_evaluadores`	Diferencia entre las dos evaluaciones. Vacío si solo hubo una.
`archivo_jpg`	Ruta de la foto en la carpeta de trabajo intermedia.
`archivo_original`	Archivo original del que salió el JPG.
`sha256`	Huella del archivo original, usada para detectar duplicados.
`fecha_hora`, `camara`	Fecha y hora, y teléfono con el que se tomó, según los metadatos.
`ancho`, `alto`	Tamaño del JPG en píxeles.
`profundidad`	si cuando el HEIC original traía mapa de profundidad (LiDAR). Los JPG no lo incluyen.
`marcado_por`, `marcado_en`	Quién marcó la vista y cuándo (hora UTC).

Todas las fotos de una misma vaca tienen los mismos valores de BCS y de pliegue.

`vacas.csv` (una fila por vaca con fotos, 67)

Cuadro 9: Columnas de `vacas.csv`.

Columna	Descripción
`id_vaca`	ID de la vaca.
`en_entrenamiento`	si cuando la vaca tiene al menos una foto usable y BCS.
`fold`	Pliegue (0 a 4).
`bcs_entrenamiento`, `bcs_1`, `bcs_2`, `n_eval`, `dif_evaluadores`	Igual que en `indice_imagenes.csv`.
`n_fotos`	Total de fotos de la vaca, incluidas las descartadas.
`n_usables`	Fotos usables.
`n_posterior`, `n_lateral_izq`, `n_lateral_der`	Fotos usables de cada vista.

`evaluaciones.csv` (una fila por evaluación, 81)

Cuadro 10: Columnas de `evaluaciones.csv`.

Columna	Descripción
`fila_excel`	Fila de la bitácora original, para ubicar la evaluación.
`id_vaca`	ID de la vaca.
`hora`	Hora de la evaluación (HH:MM). Vacía si la bitácora decía "x" o venía en otro formato.
`bcs`	BCS de esa evaluación, sin promediar.
`orden_evaluacion`	1 o 2, según el orden en la bitácora.
`n_eval`	Número de evaluaciones de la vaca.
`fold`, `en_entrenamiento`	Pliegue de la vaca y si entra al entrenamiento.

Distribución del BCS de las 81 evaluaciones: 2.25 (1), 2.50 (15), 2.75 (13), 3.00 (20), 3.25 (15), 3.50 (10) y 3.75 (7). El rango es el mismo de 2.1, de 2.25 a 3.75, así que el modelo no verá vacas fuera de ese rango.

3.6.3. Pendientes por aclarar

- Con Aurelio: qué mide "Evento BCS", para decidir si se usa en alguna fase posterior.
- Con el CAETEC: auditar las 7 vacas con etiqueta "fresca" contradictoria.
- En equipo: confirmar la exclusión de la vaca 2123.
- En equipo: definir si otra persona revisa una muestra de las vistas marcadas.
- En equipo: decidir si marcar_vistas.html entra al repositorio o solo se menciona en este reporte.
- En equipo: decidir si el procesamiento se queda en pandas o pasa a PySpark en AWS.
- En equipo: decidir qué pasa con los scripts del bucket (la versión con PySpark y la comparación de tiempos).
- En equipo: indicar en qué carpeta del bucket queda dataset_bcs/.