

Inteligencia artificial avanzada para la ciencia de datos

Evaluación inicial de herramientas y técnicas

Facundo Bautista Barbera
A01066843

Emiliano Camacho Ponce
A01712408

Oswaldo Isaias Hernandez Santes
A01199004

Iker Mejia Hernandez
A01352358

Alfredo Alejandro Soto Herrera
A01711368

Jorge Manuel Oyoqui Aguilera
A01711783

7 de octubre de 2026

Introducción

En esta sección se evalúan las herramientas y técnicas candidatas para cada objetivo de minería de datos (DM-1 a DM-6). Para cada una se indica por qué se eligió y qué alternativa existe en caso de que no funcione. La selección considera los recursos disponibles (Inventario de recursos) y los riesgos identificados (Riesgos y contingencias).

Lenguaje y entorno

Todo el desarrollo se hará en Python, por ser el lenguaje con mayor soporte para ciencia de datos y aprendizaje profundo, y el que el equipo ya domina.

- **Jupyter Notebooks:** entorno para visualizar y manipular datos usando código; se usará en la exploración y la experimentación.
- **VS Code:** edición del código que se reutiliza entre notebooks.
- **Git/GitHub:** control de versiones y seguimiento de tareas. Los datos del CAETEC no se suben al repositorio; se guardan fuera de él.

Captura y preparación de imágenes (DM-3)

Herramienta / técnica	Uso	Alternativa
Record3D o Stray Scanner (iPhone)	Capturar RGB y profundidad del LiDAR por cuadro	Solo RGB con la cámara estándar
Label Studio o CVAT	Registrar el BCS asignado por el experto y marcar a cada vaca	Hoja de cálculo con el ID de la imagen y su BCS
Segment Anything (SAM) o YOLOv8-seg	Recortar la vaca y quitar el fondo, para que el modelo no aprenda del entorno	Recorte manual con bounding box
Albumentations	Data augmentation para compensar un dataset chico	Transformaciones propias de Keras

Nota: el LiDAR solo está en los iPhone Pro. Si no se consigue uno, la contingencia es trabajar solo con RGB.

Estimación del BCS y detección de vacas en riesgo (DM-3 y DM-4)

Herramienta / técnica	Uso	Alternativa
TensorFlow / Keras	Diseño y entrenamiento de las CNN	PyTorch
ResNet18 preentrenada (ImageNet)	Base de cada rama del modelo; reduce la cantidad de datos necesaria	EfficientNet o MobileNet
Arquitectura two-stream con late fusion	Una rama aprende de RGB (textura) y otra de profundidad (geometría); la literatura reporta mejores resultados con late fusion	Una sola rama RGB
GroupKFold (scikit-learn)	Separar entrenamiento y prueba por vaca para evitar data leakage	División manual por ID de vaca
MAE y RMSE	Medir el error del BCS estimado (criterio: $MAE \leq 0.25$)	—
Umbrales y media móvil por vaca	DM-4: marcar vacas con $BCS \geq 4.00$, ≤ 2.25 o con tendencia a caer debajo de 2.75	Regresión lineal sobre la serie de cada vaca

Saturación de los robots y colas (DM-1 y DM-2)

Herramienta / técnica	Uso	Alternativa
pandas	Agrupar los registros del VMS por robot y por hora	PySpark si el volumen lo requiere
LightGBM o XGBoost con variables de rezago	DM-1: pronosticar a 2 horas si un robot superará el 90 % de utilización	SARIMA (statsmodels) o Prophet
Modelo base estacional	Comparar el pronóstico contra “lo mismo que a esta hora la semana pasada”	—
Teoría de colas (M/M/c)	DM-2: estimar la espera a partir del tiempo ocioso entre ordeños	Simulación con SimPy

Monopolización y flujo bimodal (DM-5 y DM-6)

Herramienta / técnica	Uso	Alternativa
Análisis descriptivo (pandas, Matplotlib, Seaborn)	DM-5: frecuencia y orden de entrada por vaca en horas pico	—
Detección de picos (scipy.signal.find_peaks)	DM-6: identificar sesiones con dos picos en el perfil de flujo	Reglas sobre el tiempo hasta el flujo máximo
Random Forest (scikit-learn)	DM-6: clasificar sesiones bimodales	Regresión logística

Nota: DM-6 depende de que el VMS exporte el perfil de flujo por ordeño; se confirmará en Data Understanding.

Herramientas transversales

- **NumPy, pandas, Matplotlib, Seaborn:** exploración, métricas y visualización.
- **scikit-learn:** preprocesamiento, validación, clustering y reducción de dimensiones.
- **MLflow o Weights & Biases:** registrar los experimentos y sus métricas para comparar modelos.
- **Cómputo:** computadora con RTX 4070 Ti para el entrenamiento; Google Colab como respaldo.

Conclusión

Las herramientas elegidas son de código abierto y funcionan con el equipo disponible, por lo que no agregan costos. Las técnicas se apoyan en la literatura revisada en Antecedentes y cada una tiene una alternativa más simple en caso de falta de datos o de tiempo, en línea con el plan de contingencia.