

Inteligencia artificial avanzada para la ciencia de datos

Business Understanding

Facundo Bautista Barbera
A01066843

Emiliano Camacho Ponce
A01712408

Oswaldo Isaías Hernández Santes
A01199004

Iker Mejía Hernández
A01352358

Alfredo Alejandro Soto Herrera
A01711368

Jorge Manuel Oyoqui Aguilera
A01711783

9 de octubre de 2026

Índice

1.1	Determinar los objetivos del negocio	2
1.1.1	Antecedentes	2
1.1.2	Objetivos de negocio	4
1.1.3	Criterios de éxito	6
1.2	Evaluar la situación	7
1.2.1	Inventario de recursos	7
1.2.2	Requerimientos, supuestos y restricciones	9
1.2.3	Riesgos y contingencias	10
1.2.4	Terminología	12
1.2.5	Costos y beneficios	14
1.3	Determinar los objetivos de minería de datos	17
1.3.1	Objetivos de minería de datos	17
1.3.2	Criterios de éxito de minería de datos	18
1.4	Elaborar el plan del proyecto	19
1.4.1	Plan de proyecto	19
1.4.2	Evaluación inicial de herramientas y técnicas	19

1.1. Determinar los objetivos del negocio

1.1.1. Antecedentes

Sobre el CAETEC

El CAETEC (Campo Agropecuario Experimental del Tecnológico de Monterrey), es el laboratorio más extenso en territorio (70 hectáreas) con el que cuenta actualmente el sistema del Tecnológico de Monterrey en México. Está ubicado en el km 188 de la carretera México-Querétaro. A casi 50 años de su creación, el CAETEC es reconocido como un laboratorio donde se desarrollan soluciones innovadoras que toman en cuenta al medioambiente, el bienestar animal y finalmente la salud del ser humano.

Su principal función es generar datos y analizar esa información para entender mejor cómo cambiar de manera positiva la agricultura y producir de forma sustentable.

Con el paso del tiempo el CAETEC ha ido evolucionando, pasó de ser un espacio para que los estudiantes hicieran prácticas a ser un espacio también enfocado en la ciencia y análisis de datos. En sus instalaciones, cuenta con tecnologías como sistemas de monitoreo, inteligencia artificial, sensores, drones, GPS y sistemas automatizados que ayudan a mejorar la eficiencia y la productividad de diversas actividades agropecuarias.

También realizan diversas actividades de agricultura, pero, dados los objetivos del proyecto, nuestro interés y enfoque está más centrado en la parte de su establo de vacas.

Su establo cuenta con alrededor de 160 vacas y utilizan sistemas de ordeño automático para la producción de leche. Tienen tres de los cinco robots que hay en todo México de la marca DeLaval que permiten llevar un registro de la producción de cada vaca y ordeñar a las vacas de forma automatizada, colocando chupones en cada ubre para extraer la leche.

Gracias a todas estas tecnologías a las cuales tiene acceso el CAETEC, actualmente se encuentran trabajando de la mano con Nestlé en un proyecto estratégico a nivel global, para encontrar acciones que ayuden a reducir las emisiones de metano que producen el estiércol de las vacas.

Artículos revisados

Los siguientes artículos nos permitieron entender el problema relacionado al Body Condition Score de las vacas, ya que tratan sobre cámaras aplicadas en las vacas, redes neuronales convolucionales, lecturas 3D, etc., lo cual puede aplicarse a una posible solución de este problema.

Un método mejorado para la medición automatizada de la condición corporal en vacas lecheras mediante un sistema de cámara tridimensional

<https://www.webofscience.com/wos/woscc/full-record/WOS:000752643700001>

En este trabajo se tienen 32 vacas Holstein (la misma raza que las del CAETEC), y se compara la cámara 3D contra la opinión de 3 evaluadores humanos durante 7 semanas. En las conclusiones, el aporte clave que se tiene es que las mediciones automáticas tienen algo de ruido y por ello se suavizó la serie temporal de cada vaca, lo que permitió que se mejorara la detección.

Evaluación automatizada de la condición corporal de vacas lecheras mediante la extracción de características tridimensionales de múltiples regiones corporales

<https://www.webofscience.com/wos/woscc/full-record/WOS:000464425700047>

En este segundo artículo, se trabajó con 44 vacas, este artículo es muy importante para este trabajo ya que nos permite tener una idea de cómo implementar un modelo, ya que en este, en particular, se espera que el modelo reciba 3 vistas, siendo estas una superior, otra lateral y finalmente una posterior. Lo que el modelo intenta buscar en las imágenes son 8 regiones corporales, prominencias óseas y depresiones. Gracias a esto es que se puede obtener una idea de cómo poder construir un modelo.

Evaluación automatizada de la condición corporal de las vacas mediante múltiples cámaras 3D y redes neuronales convolucionales

<https://www.webofscience.com/wos/woscc/full-record/WOS:001113690300001>

Siguiendo con el artículo anterior, este tercero nos da más ideas sobre la construcción del modelo, en este caso se utilizaron 462 vacas para el estudio, donde un gran aporte es que se utilice una vaca completa en Train o Test, es decir, que no haya fotos de la misma vaca en Train y Test ya que esto provocaría Data Leakage. Además de que se prueba con early, mid y Late Fusion, en donde gana Late, algo que se puede tomar en consideración.

Evaluación automatizada en tiempo real de la condición corporal de vacas lecheras en una sala de ordeño rotativa comercial mediante aprendizaje profundo de dos flujos RGB-D

<https://www.webofscience.com/wos/woscc/full-record/WOS:001836452900001>

Por otro lado, en este cuarto trabajo, ampliamos lo que se había investigado ya que se utiliza RGB-D en vez de una cámara 3D para ver qué resulta mejor. En este trabajo se utilizaron 1025 vacas, generando finalmente 25700 pares de RGB-D. El pipeline que siguieron fue RFID → adquisición RGB-D → detección de vaca → extracción de región → alineamiento RGB/depth → modelo → BCS.

Además, utilizan Two-Stream ResNet18 con Late Fusion (lo que en el artículo anterior vimos que era mejor opción). Esto hace que RGB pueda aprender apariencia, textura, bordes, etc. Mientras que el Depth aprende geometría y forma corporal. Este trabajo se alinea más con lo que podríamos hacer que los anteriores al no utilizar cámaras 3D.

Los artículos anteriores nos dan una buena idea de qué modelo poder crear para calcular el BCS, y los siguientes serían de apoyo para entender mejor el mundo de la ganadería enfocado en las vacas.

AI-powered cow detection in complex farm environments

<https://www.webofscience.com/wos/woscc/full-record/WOS:001398182100001>

Este artículo nos ayuda a entender cómo tomar las imágenes en la visita al CAETEC para fotografiar a las vacas, esto debido a que el paper muestra la lista de problemas comunes que puede presentar un dataset de vacas, como la iluminación, poses, fondo, escala, ángulo, altura de la cámara, oclusiones, etc.

Using big data in cattle practice

<https://www.webofscience.com/wos/woscc/full-record/WOS:000454457600004>

Por otro lado tenemos este artículo en el que se presenta el Big Data como posible uso en la medicina ganadera, en donde se aplican las cuatro V para poder medir la ganadería bovina. Volumen, variedad, velocidad y veracidad. En este trabajo se llega a la conclusión de que es complicado obtener datos veraces más que un volumen alto, ya que los sensores pueden presentar fallas de calibración o presentar ruido, etc. Este artículo resulta de gran ayuda ya que nos brinda la idea de utilizar o no Big Data en el trabajo.

Finalmente, tenemos la sección de artículos que nos brindan contexto de la situación, cómo es que funciona un ordeño, cómo es un rancho normalmente, entre otras cuestiones que ayudan a comprender todo lo necesario sobre las vacas sin entrar en aspectos tecnológicos o alguna invención que nos pudiera ayudar al modelo.

Importance of body condition score and ovarian activity on determining the fertility in beef cows supplemented with long-acting progesterone after timed-AI

<https://www.webofscience.com/wos/woscc/full-record/WOS:000449567400004>

El objetivo de este artículo es poder entender la importancia del BCS y por qué queremos hacer un modelo que pueda detectarlo, en este artículo se trabaja con 1054 vacas Holstein en donde se creó un modelo que predijera el BCS y además se entrenó con datos como la edad, peso, enfermedades, etc. y entender si importa el BCS para la preñez en las vacas. El resultado mostró que las vacas con BCS menor a 2.75 tuvieron un 59 % de preñez, mientras que las vacas con BCS aún más bajo tiene una preñez de 41.5 %.

The Association of Delayed Milk Ejection and Milk Production in Dairy Cows Milked by an Automated Milking System

<https://www.webofscience.com/wos/woscc/full-record/WOS:001463698600001>

Finalmente en este artículo se analiza el efecto del retraso en la eyección de leche sobre la producción de leche en un sistema de ordeño automatizado, se analizaron 689,484 registros de ordeño individual y 194,142 observaciones diarias de 1,573 vacas durante 350 días. En ordeños individuales, la presencia de bimodalidad reduce el rendimiento en 1.2 kg por sesión debido a una preparación/estimulación inadecuada del pezón o fallas en el vacío. Paradójicamente, las vacas que mostraron DME con mayor frecuencia diaria presentaron en general una mayor producción diaria de leche (diferencias de 1.5 a 7.4 kg/día). Esto se debe a que las vacas de alta producción acuden con mayor frecuencia al robot (hasta 6 ordeños/día).

1.1.2. Objetivos de negocio

Propósito y visión global

Aprovechando la infraestructura tecnológica del CAETEC, transformar la gestión del establo lechero hacia un modelo de ganadería de precisión 4.0 proactiva. El proyecto fusiona la telemetría continua de los 3 robots con la captura multimodal de dispositivos móviles accesibles (iPhone RGB + LiDAR), transformando datos de sensores en decisiones operativas automatizadas que

preserven el bienestar animal, eviten mermas productivas por estrés y aseguren la viabilidad reproductiva de las 160 vacas Holstein del hato.

Objetivo general del negocio

Permitir evaluar de forma frecuente y no invasiva la Condición Corporal (BCS) de cada vaca, con equipo accesible para el personal del establo, buscando prevenir caídas de BCS por debajo de 2.75 para evitar el colapso de fertilidad postparto. **Objetivo secundario:** anticipar y mitigar la saturación operativa de las 3 estaciones DeLaval VMS del CAETEC, para reducir las esperas en la manga, mejorar la distribución del tráfico de las vacas a lo largo del día y prevenir caídas de producción por eyección retardada. Todo esto orientado a elevar los litros de leche recolectados, garantizar el bienestar de los animales y optimizar la rentabilidad del socio.

Objetivos específicos del negocio por eje estratégico

Eje A (principal): salud, bienestar y condición corporal (BCS)

- **Evaluación objetiva y frecuente de la condición corporal:** sustituir la evaluación visual esporádica del BCS por una evaluación frecuente, no invasiva y consistente, realizada en el propio establo, que permita dar seguimiento a cada vaca a lo largo de la lactancia.
- **Viabilidad reproductiva:** detectar a tiempo a las vacas en postparto cuyo BCS tiende a caer por debajo de 2.75, para ajustar su nutrición y manejo antes de que se comprometa la preñez. (Se apoya en el artículo sobre BCS y fertilidad revisado en 1.1.1).
- **Prevención proactiva de patologías metabólicas:** alertar a los nutricionistas y veterinarios cuando una vaca entre en periodo seco con sobrepeso ($BCS > 4$) o presente emaciación severa ($BCS < 2.25$), previniendo cetosis clínica, hígado graso e hipocalcemia.

Eje B: eficiencia operativa, capacidad y teoría de colas en el VMS

- **Mitigación de la eyección retardada de leche (DME) y del flujo bimodal:** con base en la literatura (artículo sobre eyección retardada revisado en 1.1.1, donde el flujo bimodal genera pérdidas de 1.2 kg de leche por sesión), reducir los tiempos muertos y el nerviosismo en la manga de acceso para asegurar que la estimulación del pezón induzca una bajada continua y homogénea de leche.
- **Protección de vacas primíparas:** evitar que las vacas dominantes de alta producción lleguen a monopolizar el VMS, garantizando que otras vacas alcancen la frecuencia óptima de ordeño sin sufrir desplazamientos agresivos en la fila.
- **Anticipación de colapsos:** evitar que cualquiera de los 3 robots opere saturado durante periodos prolongados, dando al personal de campo aviso con anticipación suficiente para rebalancear el tráfico de las 160 vacas antes de que se forme una cola física prolongada.

Indicadores clave de desempeño del negocio (KPI)

Indicador de negocio	Línea base	Meta esperada	Impacto cuantitativo en el establo del CAETEC
Pérdida por flujo bimodal (DME)	Merma recurrente no monitoreada de 1.2 kg por ordeño atípico.	Reducción del 40 % en sesiones bimodales por estrés de espera.	Recuperación de hasta 150–200 kg de leche diarios en el hato de 160 vacas.
Horas diarias de saturación robótica (>90 %)	4–6 horas/día con colapso silencioso de manga.	Reducción del 35 % de horas de colapso mediante alertas anticipadas.	Aprovechamiento óptimo de los 3 robots DeLaval VMS del CAETEC.
Tiempo de espera promedio en la manga	Picos de hasta 45–90 min en horas pico de alimento.	≤20 minutos sostenidos en horas pico.	Mayor tiempo de rumia y aumento estimado de 1.0 a 1.8 kg de leche/vaca/día.

1.1.3. Criterios de éxito

El éxito del proyecto se determina con indicadores del establo, comparados contra la línea base previa a la solución. La línea base se obtiene de los registros históricos de los 3 robots DeLaval VMS y de las evaluaciones visuales de BCS del personal. Los criterios técnicos del modelo se definen en 1.3.2.

Criterios objetivos

- **Saturación de los robots:** las horas diarias con algún robot por encima del 90 % de utilización (línea base: 4 a 6 horas al día) se reducen al menos 35 %. Se mide con la utilización por robot y por hora en los registros del VMS. Evalúa: responsable del establo.
- **Espera en la manga:** el tiempo de espera promedio en horas pico (línea base: picos de 45 a 90 minutos) se mantiene en 20 minutos o menos. Se estima con el tiempo ocioso entre ordeños consecutivos, porque el VMS no registra la fila, y se valida con observación directa. Evalúa: responsable del establo y médico veterinario.
- **Flujo bimodal y producción:** las sesiones con flujo bimodal disminuyen 40 % y la producción diaria del hato no baja respecto a la línea base; la meta de referencia es recuperar de 150 a 200 kg de leche al día. Se mide con la producción y el perfil de flujo por ordeño registrados por el VMS. Evalúa: responsable del establo.
- **Vacas primíparas:** las vacas primíparas y de menor jerarquía mantienen en horas pico la frecuencia de ordeño definida por el establo. Se mide con la frecuencia de ordeño por vaca y por franja horaria. Evalúa: responsable del establo.

- **Evaluación del BCS:** el personal obtiene una calificación de BCS de cada vaca al menos cada dos semanas, sin manipular al animal y en menos tiempo que con la evaluación visual actual. Evalúa: médico veterinario y nutricionista.
- **Patologías metabólicas:** todas las vacas que entran al periodo seco con $BCS \geq 4.00$ o que presentan $BCS \leq 2.25$ se notifican a nutrición y veterinaria en la semana en que se detectan. Evalúa: médico veterinario y nutricionista.
- **Viabilidad reproductiva:** disminuye la proporción de vacas en posparto con BCS menor a 2.75. Es un indicador de largo plazo; su efecto en la tasa de preñez se observa después del cierre del proyecto. Evalúa: médico veterinario.
- **Confiabilidad de la información:** el personal atiende al menos 80 % de las alertas emitidas y no deja de usarlas por falsas alarmas. Evalúa: responsable del establo.

Criterios subjetivos

- Las alertas de saturación llegan con anticipación suficiente y son claras para decidir cómo rebalancear el tráfico de vacas. Juicio: responsable del establo del CAETEC.
- La calificación automática de BCS es tan útil como la evaluación visual para decidir ajustes de nutrición y de manejo reproductivo. Juicio: médico veterinario del CAETEC.
- La solución puede operarse con el personal y el equipo actuales del establo (iPhone y registros del VMS) sin interrumpir la rutina de ordeño. Juicio: socio formador.

Horizonte y criterio mínimo de éxito

Los indicadores productivos y de salud necesitan semanas de operación para mostrar cambios. Por ello, al cierre del proyecto (diciembre de 2026) el éxito mínimo se verifica así:

- Con datos históricos del CAETEC, demostrar que las alertas habrían anticipado los periodos de saturación registrados y estimar su efecto sobre los indicadores anteriores.
- Realizar al menos una prueba de captura con iPhone en el establo y obtener la validación del médico veterinario y del responsable del establo.

La verificación completa de las metas productivas se propone para un periodo piloto posterior de al menos 8 semanas, acordado con el CAETEC.

1.2. Evaluar la situación

1.2.1. Inventario de recursos

A continuación se mencionan los recursos a los cuales el equipo tuvo total acceso para llevar a cabo la realización de este proyecto:

Expertos

- Dr. Benjamín Valdés Aguirre
- Mtro. Eduardo Daniel Juárez Pineda
- Dr. José Antonio Cantoral-Ceballos
- Dr. Aurelio Guevara Escobar
- Lupita
- Colaboradores del CAETEC

Datos

Para la realización del proyecto y entrenamiento de los modelos, fue indispensable contar con los siguientes datos tabulares en formato .csv extraídos de los dispositivos con los que interactúan las vacas.

Los siguientes datos fueron proporcionados por el socio formador:

1. Concentrados de alimento consumido de cada vaca hasta enero de 2026
2. Producción de leche por sesión de ordeño de cada vaca hasta enero de 2026
3. Registros detallados de los ordeños de cada vaca, patadas e inventario total de marzo a junio de 2025

También se recolectaron varias imágenes de distintas vacas para resolver el problema del BCS. Estos datos fueron recopilados por distintos integrantes de los equipos del proyecto de la concentración.

Recursos de cómputo (hardware)

Recurso	Especificaciones	Propietario / Acceso	Uso en el proyecto
Computadora de escritorio	CPU: Intel Core i7-12700k GPU: NVIDIA GeForce RTX 4070 Ti 12GB RAM: 32GB 2TB SSD NVMe M.2	Emiliano Camacho Ponce	Entrenamiento de los modelos
Cámara de teléfono	Modelo: iPhone 14 Cámara: 12 MP con campo de visión de 120 grados. Formato: 4:3	Alfredo Alejandro Soto Herrera	Teléfono con el cual se tomaron las imágenes

Cabe mencionar que para la recopilación total de imágenes, se utilizaron otros dispositivos móviles de otros miembros de distintos equipos de la concentración. Se siguió un estándar donde todos los dispositivos utilizados fueran iPhone.

Recursos de software

Categoría	Herramienta	Versión	Uso en el proyecto
Lenguaje	Python	x.x	Desarrollo general
Deep Learning	TensorFlow	x.x	Diseño y entrenamiento de las CNNs
Análisis de datos	NumPy, pandas, Matplotlib	x.x	Exploración, métricas y visualización
Entornos de desarrollo	Jupyter, VS Code	-	Experimentación
Control de versiones y gestión	Git/GitHub	-	Trabajo en equipo y seguimiento de tareas

1.2.2. Requerimientos, supuestos y restricciones

Este proyecto cuenta con una serie de requerimientos a cumplir, empezando por las fechas importantes de entrega de avances así como la entrega final, todo esto siguiendo la metodología CRISP-DM, programado para las siguientes fechas:

- Avance sobre el apartado de “Business Understanding” programado para el 7 de octubre.
- Avance sobre “Data Understanding” para el día 20 de octubre.
- Avance en la sección “Data Preparation” estipulada para el 4 de noviembre.
- Como cuarto avance se tiene a la parte de “Modelling” en el día 15 de noviembre.
- Finalmente como avance se tiene la sección “Evaluation” predicha para el 20 de noviembre.
- La entrega final de todo el proyecto sería el 2 de diciembre.

El segundo requerimiento a tener en cuenta son los datos, cómo es que vienen pero enfocado en su comprensión y calidad, en este caso no se profundiza mucho en ello ya que esto es parte de la sección de “Data Understanding” siguiendo con la metodología CRISP-DM. Por lo que solo nos centramos en explicar lo justo y necesario. Los datos que tenemos son archivos de Excel por vaca en donde se registra diariamente la producción de leche de la vaca. En estos archivos podemos ver un orden claro, sin valores faltantes o nulos en la mayoría de columnas, aunque hay algunas que sí tienen instancias con valores faltantes. Por lo que podemos decir que los datos son de fácil comprensión debido a su buen orden y con una calidad alta por tener tanta información y con muy pocas casillas faltantes.

En cuanto a seguridad y aspectos legales, tenemos acceso a los datos y los podemos utilizar siempre y cuando no los introduzcamos en sitios públicos en donde otras personas ajenas a la institución puedan utilizarlos para sus intereses personales, al no estar tratando con datos de personas no existe un riesgo de que alguien salga afectado al usar sus datos, pero sí estamos tratando con el trabajo de recolección de otros, por ello es importante cuidar el uso que le damos ya que no nos pertenecen.

Supuestos

- Todas las vacas se encuentran en un rango de BCS de 2.25 a 3.75.
- El BCS dicho por los expertos será tomado como lo correcto.
- Entre más leche produzcan las vacas, mejor.
- Los datos brindados por la organización son correctos.

Restricciones

- Solo se cuenta con una oportunidad de visita para ir a conocer, entender y tomar fotografías.
- No todas las imágenes cuentan con la misma iluminación, puede ser peor o mejor.
- Solo se puede utilizar un celular iPhone para la captura de imágenes.
- Se necesita encontrar una computadora con GPU para poder entrenar el modelo.

1.2.3. Riesgos y contingencias

Dentro del proyecto pueden llegar a suscitarse situaciones en las que podamos tener retrasos o algunos fallos, a esto lo conocemos como riesgos del proyecto, para evitar que sucedan estas situaciones es necesario conocerlas y tenerlas presentes para tener cuidado con ello.

Riesgo	Nivel de riesgo (0–100)	Plan de mitigación	Plan de contingencia
Dataset chico o desbalanceado	85	Definir un mínimo de vacas a las que tomarles foto, además de decidir cuántas fotos tomar por vaca.	Utilizar algún modelo preentrenado con capas congeladas si es posible.
Calidad irregular en las fotos	80	Definir una misma vista, distancia, altura, etc. para las diferentes vacas. Además de descartar fotos borrosas.	Usar data augmentation y volver a eliminar fotos irregulares.
Data leakage por no separar por vacas	80	Separar train, validation y test por vaca y no solo al azar.	Rehacer la separación por vaca y reentrenar.
El modelo aprende cosas que no son de la vaca en sí	75	Se puede recortar o segmentar a la vaca, además de poder implementar un bounding box a la imagen.	Segmentar y enmascarar el fondo de la imagen.
Falta de tiempo al intentar resolver las 2 problemáticas	70	Acordar fechas de trabajo concretas, enfocándose primero en la determinación del BCS e ir midiendo el tiempo.	Entregar solamente BCS y dejar el concepto del problema de colas.
Restricciones técnicas	60	Utilizar un iPhone de al menos un integrante del equipo, además de conseguir una GPU para el entrenamiento.	Si no se puede conseguir una cámara con 3D, usar RGB.
Datos de producción de leche incompletos	55	En el proceso de “Data Understanding” investigar a fondo los datos en busca de algún problema mayor.	Imputar o excluir los días sin datos.

1.2.4. Terminología

Terminología del negocio

1. **CAETEC:** Campo Agropecuario Experimental del Tecnológico de Monterrey. Es el socio formador del proyecto y funciona como espacio de investigación, experimentación y aplicación de tecnologías en actividades agropecuarias.
2. **Ganado lechero:** Conjunto de bovinos destinados principalmente a la producción de leche.
3. **Vaca lechera:** Bovino hembra criado y manejado para la producción de leche.
4. **Ordeño:** Proceso mediante el cual se extrae la leche de una vaca.
5. **Sistema de ordeño automático:** Sistema tecnológico que permite realizar el ordeño con una intervención humana mínima, utilizando sensores, mecanismos y software para controlar el proceso.
6. **Cola:** Acumulación de individuos que esperan para acceder a un recurso o servicio que tiene una capacidad limitada.
7. **Producción de leche:** Cantidad de leche producida por una vaca o por el conjunto del ganado durante un periodo determinado.
8. **Condición corporal (BCS):** Evaluación del nivel de reservas corporales de una vaca mediante características visuales y/o físicas hecha por algún experto. BCS significa Body Condition Score.

Terminología de ciencia de datos e inteligencia artificial

1. **Datos:** Información que puede ser recopilada, almacenada y analizada para obtener conocimiento.
2. **Dataset:** Conjunto estructurado de datos utilizado para análisis o desarrollo de modelos.
3. **Variable:** Característica o atributo que puede tomar diferentes valores dentro de un conjunto de datos.
4. **Feature:** Variable utilizada como entrada para un modelo de aprendizaje automático.
5. **Variable objetivo:** Variable que un modelo intenta predecir o estimar.
6. **Minería de datos:** Proceso de explorar grandes cantidades de datos para identificar patrones, relaciones o información útil.
7. **Ciencia de datos:** Disciplina que combina estadística, programación, matemáticas y conocimiento del dominio para extraer información útil de los datos.
8. **Inteligencia artificial (IA):** Área de la computación dedicada al desarrollo de sistemas capaces de realizar tareas que normalmente requieren capacidades asociadas con la inteligencia humana.

9. **Aprendizaje automático (Machine Learning):** Subcampo de la IA que permite que los sistemas aprendan patrones a partir de datos para realizar predicciones o tomar decisiones.
10. **Aprendizaje profundo (Deep Learning):** Subconjunto del aprendizaje automático dentro de la inteligencia artificial, el cual imita el funcionamiento del cerebro humano mediante el uso de redes neuronales artificiales de múltiples capas.
11. **Aprendizaje supervisado:** Tipo de aprendizaje automático en el que el modelo aprende utilizando datos que contienen una respuesta o etiqueta conocida.
12. **Modelo:** Representación matemática o computacional de patrones aprendidos a partir de datos, utilizada para realizar predicciones o clasificaciones.
13. **Entrenamiento:** Proceso mediante el cual un modelo aprende los patrones presentes en los datos.
14. **Predicción:** Resultado generado por un modelo para un nuevo dato que no necesariamente fue utilizado durante el entrenamiento.
15. **Clasificación:** Tarea de aprendizaje automático en la que se asigna una observación a una categoría.
16. **Regresión:** Tarea en la que un modelo estima un valor numérico.
17. **Red neuronal artificial:** Modelo computacional inspirado en el funcionamiento de las redes neuronales biológicas, compuesto por capas de unidades que transforman información.
18. **CNN (Convolutional Neural Network):** Tipo de red neuronal especializada en procesar imágenes y detectar patrones espaciales como bordes, formas y estructuras.
19. **Visión por computadora:** Área de la IA que permite a las computadoras procesar e interpretar información contenida en imágenes o videos.
20. **Procesamiento de imágenes:** Conjunto de técnicas utilizadas para transformar, mejorar o preparar imágenes para su análisis.
21. **Etiqueta (label):** Valor asociado a un dato que representa la respuesta conocida que se desea aprender o predecir.
22. **Conjunto de entrenamiento:** Parte del dataset utilizada para entrenar el modelo.
23. **Conjunto de validación:** Datos utilizados durante el desarrollo para evaluar y ajustar el modelo sin utilizarlos directamente para entrenarlo.
24. **Conjunto de prueba:** Datos que se mantienen separados del entrenamiento para evaluar el desempeño final del modelo.
25. **Overfitting:** Situación en la que un modelo aprende demasiado los datos de entrenamiento y tiene un desempeño considerablemente peor con datos nuevos.

26. **Underfitting:** Situación en la que un modelo es demasiado simple para capturar los patrones de los datos.
27. **Generalización:** Capacidad de un modelo para producir resultados adecuados sobre datos nuevos que no utilizó durante su entrenamiento.

Terminología estadística

1. **Estadística:** Disciplina que permite recopilar, organizar, analizar e interpretar datos para obtener conclusiones.
2. **Población:** Conjunto total de individuos u observaciones que son objeto de estudio.
3. **Muestra:** Subconjunto de una población utilizado para realizar un análisis.
4. **Media:** Valor obtenido al sumar todas las observaciones y dividir las entre su cantidad.
5. **Mediana:** Valor que se encuentra en el centro de un conjunto de datos ordenado.
6. **Desviación estándar:** Medida que indica qué tan dispersos están los datos respecto a su media.
7. **Correlación:** Medida de la relación entre dos variables.
8. **Distribución:** Forma en que se encuentran organizados los valores de una variable.
9. **Métrica:** Medida utilizada para cuantificar el desempeño de un modelo o proceso.
10. **MAE (Mean Absolute Error):** Promedio del valor absoluto de las diferencias entre las predicciones y los valores reales.
11. **RMSE (Root Mean Squared Error):** Raíz cuadrada del promedio de los errores al cuadrado.
12. **Matriz de confusión:** Tabla que permite comparar las clases predichas por un modelo con las clases reales.
13. **Exactitud (accuracy):** Proporción de predicciones correctas respecto al total de predicciones.
14. **Error:** Diferencia entre un valor real y el valor estimado por un modelo.

1.2.5. Costos y beneficios

A continuación se presentan los costos y beneficios que se prevé que genere la implementación del proyecto. Todas las cantidades monetarias se presentan en pesos mexicanos (MXN).

Costos

Desarrollo del proyecto:

Concepto	Costo
Horas del equipo y de los expertos/colaboradores	\$0 (sin remuneración)
PC de entrenamiento e iPhones	\$0 (propios)
Software (Python, TensorFlow, Jupyter, Git...)	\$0 (código abierto)
Acceso al CAETEC	\$0
Gasolina de la visita extra	\$150
Total	\$150

Riesgos que pueden generar costos extra:

Riesgo	Nivel de riesgo	Costo si ocurre
Dataset chico/desbalanceado	85 %	\$300 (2 visitas)
Calidad irregular de fotos	80 %	\$150 (1 visita)
Total		\$450

Teniendo en cuenta el análisis anterior, se estima que el costo total del proyecto esté entre \$600 y \$700 pesos mexicanos.

Costos de despliegue formal en campo:

Estos son los costos previstos si se decidiera implementar este proyecto a mayor escala ya en el CAETEC. Cabe mencionar que estos costos no forman parte del proyecto a realizar y solo funcionan como un mero escenario hipotético para tener un panorama de lo que cuesta aproximadamente implementar un proyecto de este tipo ya de manera formal.

Concepto	Costo
Cámara 3D	\$10,000
Instalación y red	\$12,000
Equipo de cómputo Edge Inference	\$8,000
Mantenimiento del hardware (cada año)	\$3,000
Total	\$33,000

Beneficios anuales si el proyecto es exitoso (establo de 160 vacas)

Para el cálculo de los beneficios, partimos de los siguientes supuestos:

Cabe recalcar que todos estos porcentajes y montos son meras estimaciones del equipo.

Beneficio	Supuesto
Mano de obra	Calificar el BCS a mano toma 3 min por vaca, una vez al mes, a \$120/h
Salud y reproducción	5 % del establo tiene un problema ligado al BCS (como cetosis por ejemplo), la detección temprana evita el 30 % y cada caso cuesta \$8,000
Concentrado	8 kg por vaca al día a \$7/kg, con un ahorro de 1 %
Colas	Cada vaca produce 0.2 L más al día y la leche se vende a \$8.50/L

Beneficio	Cómo se calcula	Por año
Ahorro de mano de obra	Calificar el BCS a mano toma 3 min por vaca al mes: $160 \times 3 \text{ min} \times 12 = 96$ h/año, a \$120/h	\$11,500
Menos problemas de salud y reproducción	5 % del establo tiene un problema ligado al BCS; detectarlo a tiempo evita el 30 % (≈ 2.4 casos) a $\sim$ \$8,000 cada uno	\$19,200
Ajuste del concentrado	El campo gasta $\sim$ \$3.27 M/año en concentrado ($160 \text{ vacas} \times 8 \text{ kg} \times \7×365); dar la ración según el BCS ahorra 1 %	\$32,700
Subtotal BCS		\$63,400
Solución de las colas	Si bajan las esperas, el robot se aprovecha mejor y cada vaca da $\sim$ 0.2 L más al día: $160 \times 0.2 \times 365 = 11,680 \text{ L}$ $\times \$8.50$	\$99,300

El análisis costo-beneficio indica que el proyecto es económicamente viable y de muy bajo riesgo financiero. Nuestro costo real de desarrollo es mínimo, solo existen gastos de transporte y gasolina si los riesgos del dataset obligaran a hacer visitas adicionales. Esto se debe a que el tiempo del equipo y de los expertos del CAETEC es una aportación sin remuneración, y el equipo, el software y el acceso al campo no tienen costo.

La mayor parte del beneficio proviene del ajuste de concentrado según el BCS y de la posible solución al problema de las colas, aunque esta última es la parte más incierta por el riesgo de

falta de tiempo.

1.3. Determinar los objetivos de minería de datos

1.3.1. Objetivos de minería de datos

Eje A. Salud, bienestar y condición corporal

- **DM-3. Estimación de la condición corporal.** Estimar el BCS de cada vaca en escala continua de 1.00 a 5.00 con una arquitectura RGB + LiDAR a partir de imágenes capturadas con iPhone. Siguiendo la literatura (artículo sobre RGB-D revisado en 1.1.1), el canal RGB captura textura y musculatura, y el canal de profundidad aísla la geometría tridimensional. Tipo de problema: regresión supervisada sobre imágenes.
- **DM-4. Detección de vacas en riesgo por BCS.** Con el BCS estimado por DM-3 y su seguimiento por vaca (al menos una estimación cada dos semanas), señalar a las vacas que:
 - entran al periodo seco con $BCS \geq 4.00$;
 - presentan $BCS \leq 2.25$;
 - en posparto caen o tienden a caer por debajo de 2.75.

Tipo de problema: clasificación por umbrales y detección de tendencia sobre series por vaca.

Eje B. Eficiencia operativa y teoría de colas en el VMS

- **DM-1. Pronóstico de saturación.** Pronosticar con una ventana de 2 horas cuándo cualquiera de los 3 robots DeLaval VMS superará el umbral del 90 % de utilización, a partir de los registros de ordeño. Tipo de problema: pronóstico de series de tiempo con salida de clasificación binaria (supera o no el umbral).
- **DM-2. Estimación de la congestión de la cola.** Deducir la congestión de la fila, que el VMS no registra, a partir del tiempo ocioso entre ordeños consecutivos (teoría de colas), para caracterizar el flujo circadiano de vacas hacia los robots.
- **DM-5. Detección de monopolización y desplazamiento.** Con la frecuencia de visitas y el orden de entrada por vaca, identificar a las vacas dominantes que concentran el uso del VMS y a las primíparas o de menor jerarquía cuya frecuencia de ordeño en horas pico queda por debajo de la definida por el establo. Tipo de problema: análisis descriptivo y detección de desviaciones.
- **DM-6. Detección de flujo bimodal.** Clasificar las sesiones con flujo bimodal a partir del perfil de flujo por ordeño del VMS y relacionar su incidencia con la espera estimada en DM-2, para dimensionar la leche recuperable (referencia: 1.2 kg por sesión, según el artículo sobre eyección retardada revisado en 1.1.1). Tipo de problema: clasificación supervisada.

1.3.2. Criterios de éxito de minería de datos

Criterios objetivos

- **DM-1. Pronóstico de saturación.** El modelo tendrá éxito si detecta al menos el 80 % de los eventos en que algún robot supera el 90 % de utilización dentro de la ventana de 2 horas ($\text{recall} \geq 80\%$), con una precisión de al menos 70 % en sus alertas. Esto equivale a aproximadamente una falsa alarma por robot por día como máximo, un nivel que el personal puede tolerar sin dejar de usar el sistema. Además, debe superar en F1 a un modelo base sencillo, como el promedio histórico de utilización por hora; de lo contrario, la complejidad del modelo no se justifica.
- **DM-2. Estimación de la congestión de la cola.** Como el VMS no registra la fila, el criterio es que la espera estimada a partir del tiempo ocioso entre ordeños coincida con la observación directa, con un error dentro de $\pm 20\%$ (o ± 5 minutos) en una muestra de horas pico. El segundo criterio es obtener un perfil horario de llegadas y de espera estimada para los 3 robots que caracterice el flujo circadiano y que el responsable del establo valide como representativo de la operación real.
- **DM-3. Estimación de la condición corporal.** El modelo tendrá éxito si su error absoluto medio (MAE) contra la calificación de los expertos del CAETEC es de 0.25 puntos o menos, con al menos 70 % de las predicciones dentro de ± 0.25 y al menos 90 % dentro de ± 0.50 . Estas métricas deben sostenerse en un conjunto de prueba con vacas que no aparecieron en el entrenamiento, sin una degradación relevante respecto a validación. Para justificar la arquitectura Two-Stream, también debe mejorar el desempeño de un modelo equivalente que use solo RGB; si no lo hace, el canal LiDAR no está aportando valor.
- **DM-4. Detección de vacas en riesgo por BCS.** El sistema debe identificar al menos el 85 % de las vacas con $\text{BCS} \geq 4.00$ al entrar al periodo seco o con $\text{BCS} \leq 2.25$ ($\text{recall} \geq 85\%$), porque omitir un caso tiene mayor costo que una falsa alarma, con una precisión de las alertas de al menos 70 %.
- **DM-5. Detección de monopolización y desplazamiento.** El análisis debe identificar al menos el 80 % de las vacas que, según la revisión del establo, quedan por debajo de la frecuencia de ordeño definida en horas pico ($\text{recall} \geq 80\%$), de modo que el establo pueda actuar sobre las primíparas y las vacas de menor jerarquía.
- **DM-6. Detección de flujo bimodal.** El clasificador de sesiones bimodales debe alcanzar un F1 y un recall de al menos 0.80 frente a la revisión manual de una muestra de perfiles de flujo, para que la estimación de leche recuperable sea confiable.

Criterios subjetivos

Además de las métricas, el éxito depende de tres juicios. El responsable del establo debe considerar que las alertas de saturación llegan con anticipación suficiente y son claras para decidir cómo rebalancear el tráfico. El médico veterinario debe considerar que la calificación automática

de BCS es tan útil como la evaluación visual para decidir ajustes de nutrición y de manejo reproductivo. El socio formador debe confirmar que la solución puede operarse con el personal y el equipo actuales (iPhone y registros del VMS) sin interrumpir la rutina de ordeño.

Criterio mínimo de éxito

Dado que los indicadores productivos y de salud requieren semanas de operación para mostrar cambios, al cierre en diciembre de 2026 el éxito mínimo consiste en tres cosas. Primero, que DM-3 cumpla el MAE y los porcentajes de acierto definidos en el conjunto de prueba y que DM-4 detecte los casos de riesgo con el recall establecido. Segundo, que con datos históricos del CAETEC DM-1 demuestre que habría anticipado los periodos de saturación registrados, con el recall definido, y que se estime su efecto sobre los indicadores de negocio. Tercero, que se realice al menos una prueba de captura con iPhone en el establo, validada por el médico veterinario y el responsable del establo. La verificación completa de las metas productivas y de salud se propone para un piloto posterior de al menos 8 semanas, acordado con el CAETEC.

1.4. Elaborar el plan del proyecto

1.4.1. Plan de proyecto

1.4.2. Evaluación inicial de herramientas y técnicas

Introducción

En esta sección se evalúan las herramientas y técnicas candidatas para cada objetivo de minería de datos (DM-1 a DM-6). Para cada una se indica por qué se eligió y qué alternativa existe en caso de que no funcione. La selección considera los recursos disponibles (Inventario de recursos) y los riesgos identificados (Riesgos y contingencias).

Lenguaje y entorno

Todo el desarrollo se hará en Python, por ser el lenguaje con mayor soporte para ciencia de datos y aprendizaje profundo, y el que el equipo ya domina.

- **Jupyter Notebooks:** entorno para visualizar y manipular datos usando código; se usará en la exploración y la experimentación.
- **VS Code:** edición del código que se reutiliza entre notebooks.
- **Git/GitHub:** control de versiones y seguimiento de tareas. Los datos del CAETEC no se suben al repositorio; se guardan fuera de él.

Captura y preparación de imágenes (DM-3)

Herramienta / técnica	Uso	Alternativa
Record3D o Stray Scanner (iPhone)	Capturar RGB y profundidad del LiDAR por cuadro	Solo RGB con la cámara estándar
Label Studio o CVAT	Registrar el BCS asignado por el experto y marcar a cada vaca	Hoja de cálculo con el ID de la imagen y su BCS
Segment Anything (SAM) o YOLOv8-seg	Recortar la vaca y quitar el fondo, para que el modelo no aprenda del entorno	Recorte manual con bounding box
Albumentations	Data augmentation para compensar un dataset chico	Transformaciones propias de Keras

Nota: el LiDAR solo está en los iPhone Pro. Si no se consigue uno, la contingencia es trabajar solo con RGB.

Estimación del BCS y detección de vacas en riesgo (DM-3 y DM-4)

Herramienta / técnica	Uso	Alternativa
TensorFlow / Keras	Diseño y entrenamiento de las CNN	PyTorch
ResNet18 preentrenada (ImageNet)	Base de cada rama del modelo; reduce la cantidad de datos necesaria	EfficientNet o MobileNet
Arquitectura two-stream con late fusion	Una rama aprende de RGB (textura) y otra de profundidad (geometría); la literatura reporta mejores resultados con late fusion	Una sola rama RGB
GroupKFold (scikit-learn)	Separar entrenamiento y prueba por vaca para evitar data leakage	División manual por ID de vaca
MAE y RMSE	Medir el error del BCS estimado (criterio: $MAE \leq 0.25$)	—
Umbrales y media móvil por vaca	DM-4: marcar vacas con BCS ≥ 4.00 , ≤ 2.25 o con tendencia a caer debajo de 2.75	Regresión lineal sobre la serie de cada vaca

Saturación de los robots y colas (DM-1 y DM-2)

Herramienta / técnica	Uso	Alternativa
pandas	Agrupar los registros del VMS por robot y por hora	PySpark si el volumen lo requiere
LightGBM o XGBoost con variables de rezago	DM-1: pronosticar a 2 horas si un robot superará el 90 % de utilización	SARIMA (statsmodels) o Prophet
Modelo base estacional	Comparar el pronóstico contra “lo mismo que a esta hora la semana pasada”	—
Teoría de colas (M/M/c)	DM-2: estimar la espera a partir del tiempo ocioso entre ordeños	Simulación con SimPy

Monopolización y flujo bimodal (DM-5 y DM-6)

Herramienta / técnica	Uso	Alternativa
Análisis descriptivo (pandas, Matplotlib, Seaborn)	DM-5: frecuencia y orden de entrada por vaca en horas pico	—
Detección de picos (scipy.signal.find_peaks)	DM-6: identificar sesiones con dos picos en el perfil de flujo	Reglas sobre el tiempo hasta el flujo máximo
Random Forest (scikit-learn)	DM-6: clasificar sesiones bimodales	Regresión logística

Nota: DM-6 depende de que el VMS exporte el perfil de flujo por ordeño; se confirmará en Data Understanding.

Herramientas transversales

- **NumPy, pandas, Matplotlib, Seaborn:** exploración, métricas y visualización.
- **scikit-learn:** preprocesamiento, validación, clustering y reducción de dimensiones.
- **MLflow o Weights & Biases:** registrar los experimentos y sus métricas para comparar modelos.
- **Cómputo:** computadora con RTX 4070 Ti para el entrenamiento; Google Colab como respaldo.

Conclusión

Las herramientas elegidas son de código abierto y funcionan con el equipo disponible, por lo que no agregan costos. Las técnicas se apoyan en la literatura revisada en Antecedentes y cada una tiene una alternativa más simple en caso de falta de datos o de tiempo, en línea con el plan de contingencia.