Instituto Tecnológico y de Estudios Superiores de Monterrey

**Inteligencia artificial avanzada para la ciencia de datos**

# Business Understanding

Facundo Bautista Barbera
A01066843

Emiliano Camacho Ponce
A01712408

Oswaldo Isaías Hernández Santes
A01199004

Iker Mejía Hernández
A01352358

Alfredo Alejandro Soto Herrera
A01711368

Jorge Manuel Oyoqui Aguilera
A01711783

23 de octubre de 2026

## Índice

**1.1 Determinar objetivos de negocio** **2**
1.1.1 Antecedentes / Historia . . . 2
1.1.2 Objetivos de negocio . . . 4
1.1.3 Criterios de éxito del negocio . . . 5

**1.2 Evaluar la situación** **5**
1.2.1 Nuestros recursos . . . 5
1.2.2 Requerimientos, supuestos y restricciones . . . 7
1.2.3 Riesgos y contingencias . . . 8
1.2.4 Glosario de terminología . . . 9
1.2.5 Análisis de costos y beneficios . . . 12

**1.3 Determinar objetivos de minería de datos** **14**
1.3.1 Objetivos de minería de datos . . . 14
1.3.2 Criterios de éxito de minería de datos . . . 15

**1.4 Elaborar el plan del proyecto** **15**
1.4.1 Plan del proyecto . . . 15
1.4.2 Herramientas iniciales a usar . . . 15

## 1.1. Determinar objetivos de negocio

### 1.1.1. Antecedentes / Historia

#### Sobre el CAETEC

El CAETEC (Campo Agropecuario Experimental del Tecnológico de Monterrey), es el laboratorio más extenso en territorio (70 hectáreas) con el que cuenta actualmente el sistema del Tecnológico de Monterrey en México. Está ubicado en el km 188 de la carretera México-Querétaro. A casi 50 años de su creación, el CAETEC es reconocido como un laboratorio donde se desarrollan soluciones innovadoras que toman en cuenta al medioambiente, el bienestar animal y finalmente la salud del ser humano.

Su principal función es generar datos y analizar esa información para entender mejor cómo cambiar de manera positiva la agricultura y producir de forma sustentable.

Con el paso del tiempo el CAETEC ha ido evolucionando, pasó de ser un espacio para que los estudiantes hicieran prácticas a ser un espacio también enfocado en la ciencia y análisis de datos. En sus instalaciones, cuenta con tecnologías como sistemas de monitoreo, inteligencia artificial, sensores, drones, GPS y sistemas automatizados que ayudan a mejorar la eficiencia y la productividad de diversas actividades agropecuarias.

También realizan diversas actividades de agricultura, pero, dados los objetivos del proyecto, nuestro interés y enfoque está más centrado en la parte de su establo de vacas.

Su establo cuenta con alrededor de 160 vacas y utilizan sistemas de ordeño automático para la producción de leche. Tienen tres de los cinco robots que hay en todo México de la marca DeLaval que permiten llevar un registro de la producción de cada vaca y ordeñar a las vacas de forma automatizada, colocando chupones en cada ubre para extraer la leche.

Gracias a todas estas tecnologías a las cuales tiene acceso el CAETEC, actualmente se encuentran trabajando de la mano con Nestlé en un proyecto estratégico a nivel global, para encontrar acciones que ayuden a reducir las emisiones de metano que producen el estiércol de las vacas.

#### Papers

Los siguientes papers nos permitieron entender el problema relacionado al Body Condition Score de las vacas, ya que tratan sobre cámaras aplicadas en las vacas, redes neuronales convolucionales, lecturas 3D, etc. Lo cual puede aplicarse a una posible solución de este problema.

#### Un método mejorado para la medición automatizada de la condición corporal en vacas lecheras mediante un sistema de cámara tridimensional

https://www.webofscience.com/wos/woscc/full-record/WOS:000752643700001

En este trabajo se tienen 32 vacas Holstein (mismas que las que hay en el CAETEC), y se compara la cámara 3D contra la opinión de 3 evaluadores humanos durante 7 semanas. Al final en las conclusiones el aporte clave que se tiene es que las mediciones automáticas tienen algo de ruido y por ello se suavizó la serie temporal de cada vaca, lo que permitió que se mejorara la detección.

**Evaluación automatizada de la condición corporal de vacas lecheras mediante la extracción de características tridimensionales de múltiples regiones corporales**

https://www.webofscience.com/wos/woscc/full-record/WOS:000464425700047

En este segundo artículo, se trabajó con 44 vacas, este artículo es muy importante para este trabajo ya que nos permite tener una idea de cómo implementar un modelo, ya que en este particularmente se espera que el modelo reciba 3 vistas, siendo estas una superior, otra lateral y finalmente una posterior. Lo que el modelo intenta buscar en las imágenes son 8 regiones corporales, prominencias óseas y depresiones. Gracias a esto es que se puede obtener una idea de cómo poder construir un modelo.

**Evaluación automatizada de la condición corporal de las vacas mediante múltiples cámaras 3D y redes neuronales convolucionales**

https://www.webofscience.com/wos/woscc/full-record/WOS:001113690300001

Siguiendo con el artículo anterior, este tercero nos da más ideas sobre la construcción del modelo, en este caso se utilizaron 462 vacas para el estudio, donde un gran aporte es que se utilice una vaca completa en Train o Test, es decir, que no haya fotos de la misma vaca en Train y Test ya que esto provocaría Data Leakage. Además de que se prueba con early, mid y Late Fusion, en donde gana Late, algo que se puede tomar en consideración.

**Evaluación automatizada en tiempo real de la condición corporal de vacas lecheras en una sala de ordeño rotativa comercial mediante aprendizaje profundo de dos flujos RGB-D**

https://www.webofscience.com/wos/woscc/full-record/WOS:001836452900001

Por otro lado en este cuarto trabajo, expandimos lo que se había investigado ya que se utiliza RGB-D en vez de una cámara 3D para ver qué resulta mejor. En este trabajo se utilizaron 1025 vacas, generando finalmente 25700 pares de RGB-D. El pipeline que siguieron fue RFID $\rightarrow$ adquisición RGB-D $\rightarrow$ detección de vaca $\rightarrow$ extracción de región $\rightarrow$ alineamiento RGB/depth $\rightarrow$ modelo $\rightarrow$ BCS.

Además utilizan Two-Stream ResNet18 con Late Fusion (lo que en el artículo anterior vimos que era mejor opción). Esto hace que RGB pueda aprender apariencia, textura, bordes, etc. Mientras que el Depth aprende geometría y forma corporal. Este trabajo se alinea más con lo que podríamos hacer que los anteriores al no utilizar cámaras 3D.

Los anteriores papers nos dan una buena idea de qué modelo poder crear para calcular el BCS, y los siguientes serían de apoyo para entender mejor el mundo de la ganadería enfocado en las vacas.

**AI-powered cow detection in complex farm environments**

https://www.webofscience.com/wos/woscc/full-record/WOS:001398182100001

Este artículo nos ayuda a entender cómo tomar las imágenes en la visita al CAETEC para fotografiar a las vacas, esto debido a que el paper muestra la lista de problemas comunes que puede presentar un dataset de vacas, como la iluminación, poses, fondo, escala, ángulo, altura de la cámara, oclusiones, etc.

#### Using big data in cattle practice

https://www.webofscience.com/wos/woscc/full-record/WOS:000454457600004

Por otro lado tenemos este artículo en el que se presenta el Big Data como posible uso en la medicina ganadera, en donde se aplican las 4 V's para poder medir la ganadería bovina. Volumen, variedad, velocidad y veracidad. En este trabajo se llega a la conclusión de que es complicado obtener datos veraces más que un volumen alto, ya que los sensores pueden presentar fallas de calibración o presentar ruido, etc. Este artículo resulta de gran ayuda ya que nos brinda la idea de utilizar o no Big Data en el trabajo.

Finalmente tenemos la sección de artículos que nos brindan contexto de la situación, cómo es que funciona un ordeño, cómo es un rancho normalmente, entre otras cuestiones que ayudan a comprender todo lo necesario a las vacas sin entrar en aspectos tecnológicos o alguna invención que nos pudiera ayudar al modelo.

#### Importance of body condition score and ovarian activity on determining the fertility in beef cows supplemented with long-acting progesterone after timed-AI

https://www.webofscience.com/wos/woscc/full-record/WOS:000449567400004

El objetivo de este artículo es poder entender la importancia del BCS y por qué queremos hacer un modelo que pueda detectarlo, en este artículo se trabaja con 1054 vacas Holstein en donde se creó un modelo que predijera el BCS y además se entrenó con datos como la edad, peso, enfermedades, etc. y entender si importa el BCS para la preñez en las vacas. El resultado mostró que las vacas con BCS menor a 2.75 tuvieron un 59 % de preñez, mientras que las vacas con BCS aún más bajo tiene una preñez de 41.5 %.

### 1.1.2. Objetivos de negocio

#### Propósito y visión global

Transformar la comprensión zootécnica y operativa del establo lechero experimental CAETEC (Alianza TEC – UAQ – UNAM) bajo un enfoque riguroso de Ciencia de Datos y Ganadería de Precisión 4.0. El proyecto se enfoca en la generación de conocimiento reproducible con el uso del fenotipado óptico multimodal (iPhone RGB + sensor LiDAR), abordando: la identificación oportuna de condiciones corporales potencialmente inadecuadas para la etapa de lactancia.

#### Principio metodológico de articulación entre objetivos de negocio y minería de datos

El cumplimiento de los objetivos de minería de datos contribuye al objetivo de negocio, pero no lo garantiza automáticamente. La estimación precisa del BCS constituye un componente del análisis; su utilidad para identificar riesgo metabólico depende de la disponibilidad de variables contextuales, etiquetas de referencia apropiadas y evidencia de que los resultados permiten distinguir condiciones de riesgo relevantes para el establo.

Por ello, el análisis se plantea en dos etapas complementarias independientes:

1. **Estimación de la condición corporal:** desarrollar y evaluar un modelo de regresión que estime el BCS a partir de imágenes RGB y, cuando aporte valor medible, información de profundidad LiDAR.

2. **Interpretación contextual del riesgo:** integrar el BCS estimado con los días en leche y las variables productivas disponibles para identificar animales cuya condición corporal sea potencialmente inadecuada para su etapa fisiológica.

La segunda etapa se validará de acuerdo con las etiquetas y los indicadores de referencia disponibles. Cuando no existan datos suficientes para validar el riesgo metabólico directamente, los resultados se reportarán como indicadores de riesgo potencial, sin interpretarlos como diagnósticos clínicos. Un buen resultado en la primera etapa no garantiza un buen resultado en la segunda.

#### Objetivo de Negocio 1 (ON-1): Salud metabólica y condición corporal (BCS)

#### Declaración oficial del objetivo

Estimar la condición corporal BCS de vacas productoras de leche de forma automatizada a partir de imágenes.

#### Preguntas clave de negocio (generación de conocimiento)

1. ¿Es viable sustituir o complementar la inspección visual humana tradicional mediante visión computacional accesible (iPhone RGB + LiDAR) sin perder consistencia clínica?

2. ¿Aporta el sensor de profundidad LiDAR una ventaja medible en invariancia lumínica y precisión frente a imágenes RGB convencionales en el entorno del corral?

### 1.1.3. Criterios de éxito del negocio

- **CN-1.1:** Lograr una estimación promedio consistente con la evaluación de los expertos clínicos del establo.
- **CN-1.2:** Lograr que la mayoría de vacas evaluadas estén dentro del margen de tolerancia aceptado.

## 1.2. Evaluar la situación

### 1.2.1. Nuestros recursos

A continuación se mencionan los recursos a los cuales el equipo tuvo total acceso para llevar a cabo la realización de este proyecto:

#### Expertos

- Dr. Benjamín Valdés Aguirre
- Ma. Eduardo Daniel Juárez Pineda
- Dr. Jose Antonio Cantoral-Ceballos
- Dr. Aurelio Guevara Escobar
- Colaboradores del CAETEC

### Datos

Para la realización del proyecto y entrenamiento de los modelos, fue indispensable contar con los siguientes datos tabulares en formato .csv extraídos de los dispositivos con los que interactúan las vacas.

Los siguientes datos fueron proporcionados por el socioformador:

1. Concentrados de alimento consumido de cada vaca hasta enero de 2026
2. Producción de leche por sesión de ordeño de cada vaca hasta enero de 2026
3. Registros detallados de los ordeños de cada vaca, patadas e inventario total de marzo a junio de 2025

También se recolectaron varias imágenes de distintas vacas para resolver el problema del body score. Estos datos fueron recopilados por distintos integrantes de los equipos del proyecto de la concentración.

### Recursos de cómputo (hardware)

| Recurso | Especificaciones | Propietario / Acceso | Uso en el proyecto |
|---|---|---|---|
| Computadora de escritorio | CPU: Intel Core i7-12700K<br>GPU: NVIDIA GeForce RTX 4070 Ti 12GB<br>RAM: 32GB<br>2TB SSD NVMe M.2 | Emiliano Camacho Ponce | Entrenamiento de los modelos |
| Cámara de teléfono | Modelo: iPhone 14<br>Cámara: 12 MP con campo de visión de 120 grados.<br>Formato: 4:3 | Alfredo Alejandro Soto Herrera | Teléfono con el cual se tomaron las imágenes |

Cabe mencionar que para la recopilación total de imágenes, se utilizaron otros dispositivos móviles de otros miembros de distintos equipos de la concentración. Se siguió un estándar donde todos los dispositivos utilizados fueran iPhone.

**Recursos de software**

| Categoría | Herramienta | Versión | Uso en el proyecto |
|---|---|---|---|
| Lenguaje | Python | x.x | Desarrollo general |
| Deep Learning | TensorFlow | x.x | Diseño y entrenamiento de las CNNs |
| Análisis de datos | Numpy, Pandas, Matplotlib | x.x | Exploración, métricas y visualización |
| Entornos de desarrollo | Jupyter, VS Code | – | Experimentación |
| Control de versiones y gestión | Git/GitHub | – | Trabajo en equipo y seguimiento de tareas |

### 1.2.2. Requerimientos, supuestos y restricciones

#### Requerimientos

Este proyecto cuenta con una serie de requerimientos a cumplir, empezando por las fechas importantes de entrega de avances así como la entrega final, todo esto siguiendo la metodología CRISP-DM, programado para las siguientes fechas:

- Avance sobre el apartado de "Business Understanding" programado para el 7 de octubre.
- Avance sobre "Data Understanding" para el día 20 de octubre.
- Avance en la sección "Data Preparation" estipulada para el 4 de noviembre.
- Como cuarto avance se tiene a la parte de "Modelling" en el día 15 de noviembre.
- Finalmente como avance se tiene la sección "Evaluation" predicha para el 20 de noviembre.
- La entrega final de todo el proyecto sería el 2 de diciembre.

El segundo requerimiento a tener en cuenta son los datos, cómo es que vienen pero enfocado en su comprensión y calidad, en este caso no se profundiza mucho en ello ya que esto es parte de la sección de "Data Understanding" siguiendo con la metodología CRISP-DM. Por lo que solo nos centramos en explicar lo justo y necesario. Los datos que tenemos son imágenes en formato .HEIC las cuales fueron tomadas en la visita al CAETEC, siguiendo con una vista posterior a la vaca, alineada a ella y desde más arriba; también fueron laterales de lado izquierdo y derecho, esto para seguir con un estándar en todas las vacas fotografiadas. En cuanto a calidad y resolución se tomaron de la misma manera para evitar tener una variabilidad que pueda hacer que falle el modelo.

Para el apartado de seguridad y legal, tenemos acceso a los datos y los podemos utilizar siempre y cuando no los introduzcamos en sitios públicos en donde otras personas ajenas a la institución puedan utilizarlos para sus intereses personales, al no estar tratando con datos de personas no

existe un riesgo de que alguien salga afectado al usar sus datos, pero sí estamos tratando con el trabajo de recolección de otros, por ello es importante cuidar el uso que le damos ya que no nos pertenecen.

#### Supuestos

- Todas las vacas se encuentran en un rango de BCS de 2.25 a 3.75.
- El BCS dicho por los expertos será tomado como lo correcto.
- Entre más leche producen las vacas mejor.

#### Restricciones

- Solo se cuenta con una oportunidad de visita para ir a conocer, entender y tomar fotografías.
- No todas las imágenes cuentan con la misma iluminación, puede ser peor o mejor.
- Solo se puede utilizar un celular iPhone para la captura de imágenes.
- Se necesita encontrar una computadora con GPU para poder entrenar el modelo.

### 1.2.3. Riesgos y contingencias

Dentro del proyecto pueden llegar a suscitarse situaciones en las que podamos tener retrasos o algunos fallos, a esto lo conocemos como riesgos del proyecto, para evitar que sucedan estas situaciones es necesario conocerlas y tenerlas presentes para tener cuidado con ello.

Para poder medir el riesgo como tal y no solo definirlo, nos basamos en 3 puntos importantes, la probabilidad de ocurrencia, el impacto que tendría y finalmente por medio de la multiplicación de estos 2, medir la magnitud del riesgo. La probabilidad de ocurrencia tiene una escala de valores de 0 a 100, medido en base a nuestras creencias. Para el impacto seguimos con una escala de valores enteros de 1 a 5 que representan lo siguiente:

- **1:** Se considera insignificante, no afectaría en los resultados ni en fechas de entrega.
- **2:** Un nivel menor, se tendría que volver a trabajar pero no es tan grande como para modificar las fechas de entrega.
- **3:** Este valor se considera moderado ya que afectaría en la calidad de nuestro trabajo final, lo que seguramente resultaría en un retrabajo mayor al punto anterior.
- **4:** Ahora este valor se toma en cuenta como un conflicto mayor, esto comprometería completamente algunos de los objetivos del proyecto planteados anteriormente.
- **5:** Finalmente llegamos al nivel crítico, en donde se compromete el proyecto completo.

Por otro lado, para la magnitud se tuvieron en cuenta los siguientes puntos para determinar si llega a ser algo que se tenga que mitigar o no es necesario.

- **>3.0:** Nivel de magnitud alto, lo que implicaría que es obligatorio mitigar ese riesgo.

- **1.5 a 3.0:** Nivel medio, en donde se tiene que mitigar de igual forma y tener un plan de contingencia, pero solamente si implica un bajo costo monetario y temporal.
- **<1.5:** Si es un valor menor a 1.5 se acepta el riesgo aunque se monitorea, ya que se consideraría de magnitud baja.

| Riesgo | Probabilidad de ocurrencia | Impacto | Magnitud | Plan de mitigación | Plan de contingencia |
|---|---|---|---|---|---|
| Dataset chico o desbalanceado | 85 % | 5 | 4.25 | Definir un mínimo de vacas a las que tomarles foto, además de decidir cuántas fotos tomar por vaca. | Utilizar algún modelo preentrenado con capas congeladas si es posible. |
| Calidad irregular en las fotos | 80 % | 5 | 4.0 | Definir una misma vista, distancia, altura, etc. para las diferentes vacas. Además de descartar fotos borrosas. | Usar data augmentation y volver a eliminar fotos irregulares. |
| Data leakage por no separar por vacas | 80 % | 4 | 3.20 | Separar train, validation y test por vaca y no solo al azar. | Rehacer la separación por vaca y reentrenar. |
| El modelo aprende cosas que no son de la vaca en sí | 75 % | 4 | 3.0 | Se puede recortar o segmentar a la vaca, además de poder implementar un bounding box a la imagen. | Segmentar y enmascarar el fondo de la imagen. |
| Restricciones técnicas | 60 % | 3 | 1.80 | Utilizar un iPhone de al menos un integrante del equipo, además de conseguir una GPU para el entrenamiento. | Si no se puede conseguir una cámara con 3D, usar RGB. |

### 1.2.4. Glosario de terminología

#### Terminología del negocio

1. **CAETEC:** Campo Agro Experimental del Tecnológico de Monterrey. Es el socioformador del proyecto y funciona como espacio de investigación, experimentación y aplicación de tecnologías en actividades agropecuarias.

2. **Ganado lechero:** Conjunto de bovinos destinados principalmente a la producción de leche.
3. **Vaca lechera:** Bovino hembra criado y manejado para la producción de leche.
4. **Ordeño:** Proceso mediante el cual se extrae la leche de una vaca.
5. **Sistema de ordeño automático:** Sistema tecnológico que permite realizar el ordeño con una intervención humana mínima, utilizando sensores, mecanismos y software para controlar el proceso.
6. **Producción de leche:** Cantidad de leche producida por una vaca o por el conjunto del ganado durante un periodo determinado.
7. **Condición corporal (BCS):** Evaluación del nivel de reservas corporales de una vaca mediante características visuales y/o físicas hecha por algún experto. BCS significa Body Condition Score.

#### Terminología de ciencia de datos e inteligencia artificial

1. **Datos:** Información que puede ser recopilada, almacenada y analizada para obtener conocimiento.
2. **Dataset:** Conjunto estructurado de datos utilizado para análisis o desarrollo de modelos.
3. **Variable:** Característica o atributo que puede tomar diferentes valores dentro de un conjunto de datos.
4. **Feature:** Variable utilizada como entrada para un modelo de aprendizaje automático.
5. **Variable objetivo:** Variable que un modelo intenta predecir o estimar.
6. **Minería de datos:** Proceso de explorar grandes cantidades de datos para identificar patrones, relaciones o información útil.
7. **Ciencia de datos:** Disciplina que combina estadística, programación, matemáticas y conocimiento del dominio para extraer información útil de los datos.
8. **Inteligencia artificial (IA):** Área de la computación dedicada al desarrollo de sistemas capaces de realizar tareas que normalmente requieren capacidades asociadas con la inteligencia humana.
9. **Aprendizaje automático (Machine Learning):** Subcampo de la IA que permite que los sistemas aprendan patrones a partir de datos para realizar predicciones o tomar decisiones.
10. **Aprendizaje profundo (Deep Learning):** Subconjunto del aprendizaje automático dentro de la inteligencia artificial, el cual imita el funcionamiento del cerebro humano mediante el uso de redes neuronales artificiales de múltiples capas.
11. **Aprendizaje supervisado:** Tipo de aprendizaje automático en el que el modelo aprende utilizando datos que contienen una respuesta o etiqueta conocida.

12. **Modelo:** Representación matemática o computacional de patrones aprendidos a partir de datos, utilizada para realizar predicciones o clasificaciones.

13. **Entrenamiento:** Proceso mediante el cual un modelo aprende los patrones presentes en los datos.

14. **Predicción:** Resultado generado por un modelo para un nuevo dato que no necesariamente fue utilizado durante el entrenamiento.

15. **Clasificación:** Tarea de aprendizaje automático en la que se asigna una observación a una categoría.

16. **Regresión:** Tarea en la que un modelo estima un valor numérico.

17. **Red neuronal artificial:** Modelo computacional inspirado en el funcionamiento de las redes neuronales biológicas, compuesto por capas de unidades que transforman información.

18. **CNN (Convolutional Neural Network):** Tipo de red neuronal especializada en procesar imágenes y detectar patrones espaciales como bordes, formas y estructuras.

19. **Visión por computadora:** Área de la IA que permite a las computadoras procesar e interpretar información contenida en imágenes o videos.

20. **Procesamiento de imágenes:** Conjunto de técnicas utilizadas para transformar, mejorar o preparar imágenes para su análisis.

21. **Etiqueta (label):** Valor asociado a un dato que representa la respuesta conocida que se desea aprender o predecir.

22. **Conjunto de entrenamiento:** Parte del dataset utilizada para entrenar el modelo.

23. **Conjunto de validación:** Datos utilizados durante el desarrollo para evaluar y ajustar el modelo sin utilizarlos directamente para entrenarlo.

24. **Conjunto de prueba:** Datos que se mantienen separados del entrenamiento para evaluar el desempeño final del modelo.

25. **Overfitting:** Situación en la que un modelo aprende demasiado los datos de entrenamiento y tiene un desempeño considerablemente peor con datos nuevos.

26. **Underfitting:** Situación en la que un modelo es demasiado simple para capturar los patrones de los datos.

27. **Generalización:** Capacidad de un modelo para producir resultados adecuados sobre datos nuevos que no utilizó durante su entrenamiento.

#### Terminología estadística

1. **Estadística:** Disciplina que permite recopilar, organizar, analizar e interpretar datos para obtener conclusiones.
2. **Población:** Conjunto total de individuos u observaciones que son objeto de estudio.
3. **Muestra:** Subconjunto de una población utilizado para realizar un análisis.
4. **Media:** Valor obtenido al sumar todas las observaciones y dividirlas entre su cantidad.
5. **Mediana:** Valor que se encuentra en el centro de un conjunto de datos ordenado.
6. **Desviación estándar:** Medida que indica qué tan dispersos están los datos respecto a su media.
7. **Correlación:** Medida de la relación entre dos variables.
8. **Distribución:** Forma en que se encuentran organizados los valores de una variable.
9. **Métrica:** Medida utilizada para cuantificar el desempeño de un modelo o proceso.
10. **MAE (Mean Absolute Error):** Promedio del valor absoluto de las diferencias entre las predicciones y los valores reales.
11. **RMSE (Root Mean Squared Error):** Raíz cuadrada del promedio de los errores al cuadrado.
12. **Matriz de confusión:** Tabla que permite comparar las clases predichas por un modelo con las clases reales.
13. **Precisión (accuracy):** Proporción de predicciones correctas respecto al total de predicciones.
14. **Error:** Diferencia entre un valor real y el valor estimado por un modelo.

### 1.2.5. Análisis de costos y beneficios

A continuación se presentan los costos y beneficios que se tienen planeados se puedan generar por la implementación del proyecto. Todas las cantidades monetarias se presentan en pesos mexicanos (MXN).

### Costos

#### Desarrollo del proyecto

| Concepto | Costo |
|---|---|
| Horas del equipo y de los expertos/colaboradores | \$0 (sin remuneración) |
| PC de entrenamiento e iPhones | \$0 (propios) |
| Software (Python, TensorFlow, Jupyter, Git...) | \$0 (código abierto) |
| Acceso al CAETEC | \$0 |
| Gasolina de la visita extra | \$150 |
| **Total** | **\$150** |

#### Riesgos que pueden generar costos extra

| Riesgo | Nivel de riesgo | Costo si ocurre |
|---|---|---|
| Dataset chico/desbalanceado | 85 % | \$300 (2 visitas) |
| Calidad irregular de fotos | 80 % | \$150 (1 visita) |
| **Total** | **\$450** | |

Teniendo en cuenta el análisis anterior, se estima que el costo total del proyecto esté en un rango de \$600 – \$700 pesos mexicanos.

#### Costos de despliegue formal en campo

Estos costos son los que se tienen previstos que habría si se decidiera implementar este proyecto a mayor escala ya en el CAETEC. Cabe mencionar que estos costos no forman parte del proyecto a realizar y solo funcionan como un mero escenario hipotético para tener un panorama de lo que cuesta aproximadamente implementar un proyecto de este tipo ya de manera formal.

| Concepto | Costo |
|---|---|
| Cámara 3D | \$10,000 |
| Instalación y red | \$12,000 |
| Equipo de cómputo Edge Inference | \$8,000 |
| Mantenimiento del hardware (cada año) | \$3,000 |
| **Total** | **\$33,000** |

#### Beneficios anuales si el proyecto es exitoso (establo de 160 vacas)

Para el cálculo de los beneficios, partimos de los siguientes supuestos:
Cabe recalcar que todos estos porcentajes y montos son meras estimaciones del equipo.

| Beneficio | Supuesto |
|---|---|
| Mano de obra | Calificar el BCS a mano toma 3 min por vaca, una vez al mes, a \$120/h |
| Salud y reproducción | 5 % del establo tiene un problema ligado al BCS (como cetosis por ejemplo), la detección temprana evita el 30 % y cada caso cuesta \$8,000 |
| Concentrado | 8 kg por vaca al día a \$7/kg, con un ahorro de 1 % |

| Beneficio | Cómo se calcula | Por año |
|---|---|---|
| Ahorro de mano de obra | Calificar el BCS a mano toma 3 min por vaca al mes: $160 \times 3$ min $\times 12 = 96$ h/año, a \$120/h | \$11,500 |
| Menos problemas de salud y reproducción | 5 % del establo tiene un problema ligado al BCS; detectarlo a tiempo evita el 30 % ($\approx 2.4$ casos) a $\sim$\$8,000 cada uno | \$19,200 |
| Ajuste del concentrado | El campo gasta $\sim$\$3.27 M/año en concentrado (160 vacas $\times$ 8 kg $\times$ \$7 $\times$ 365); dar la ración según el BCS ahorra 1 % | \$32,700 |
| **Subtotal BCS** | | **\$63,400** |

El análisis costo-beneficio indica que el proyecto es económicamente viable y de muy bajo riesgo financiero. Nuestro costo real de desarrollo es mínimo, solo existen gastos de transporte y gasolina si los riesgos del dataset obligaran a hacer visitas adicionales. Esto se debe a que el tiempo del equipo y de los expertos del CAETEC es una aportación sin remuneración, y el equipo, el software y el acceso al campo no tienen costo.

## 1.3. Determinar objetivos de minería de datos

### 1.3.1. Objetivos de minería de datos

Cada objetivo de negocio se transforma estrictamente en un problema formal de Ciencia de Datos y Minería de Datos. Se delimita explícitamente qué variables son observadas directamente y cuáles son inferidas analíticamente, garantizando que el alcance técnico sea congruente con los datos reales disponibles en el establo.

#### Objetivo de Minería de Datos 1 (OMD-1): Salud metabólica y condición corporal (BCS)

#### Declaración oficial del objetivo

Desarrollar y evaluar un modelo supervisado de regresión que estime la condición corporal de las vacas (BCS escala 1.0 a 5.0) a partir de imágenes RGB y datos de profundidad LiDAR.

### 1.3.2. Criterios de éxito de minería de datos

- **CMD-1.1:** Lograr que la predicción de nuestro modelo estime el BCS con un margen de error MAE (error absoluto medio) de 0.25–0.50 en comparación con el BCS predicho por los expertos.
- **CMD-1.2:** Alcanzar un porcentaje alto de predicciones cuya diferencia con el experto sea de máximo un cuarto (0.25) o media unidad (0.50) de BCS:
  - Accuracy a 0.25 puntos: 70 % de las vacas.
  - Accuracy a 0.50 puntos: 90 % de las vacas.

## 1.4. Elaborar el plan del proyecto

### 1.4.1. Plan del proyecto

https://aipordefinir.github.io/ai-model-tutsipink/

### 1.4.2. Herramientas iniciales a usar